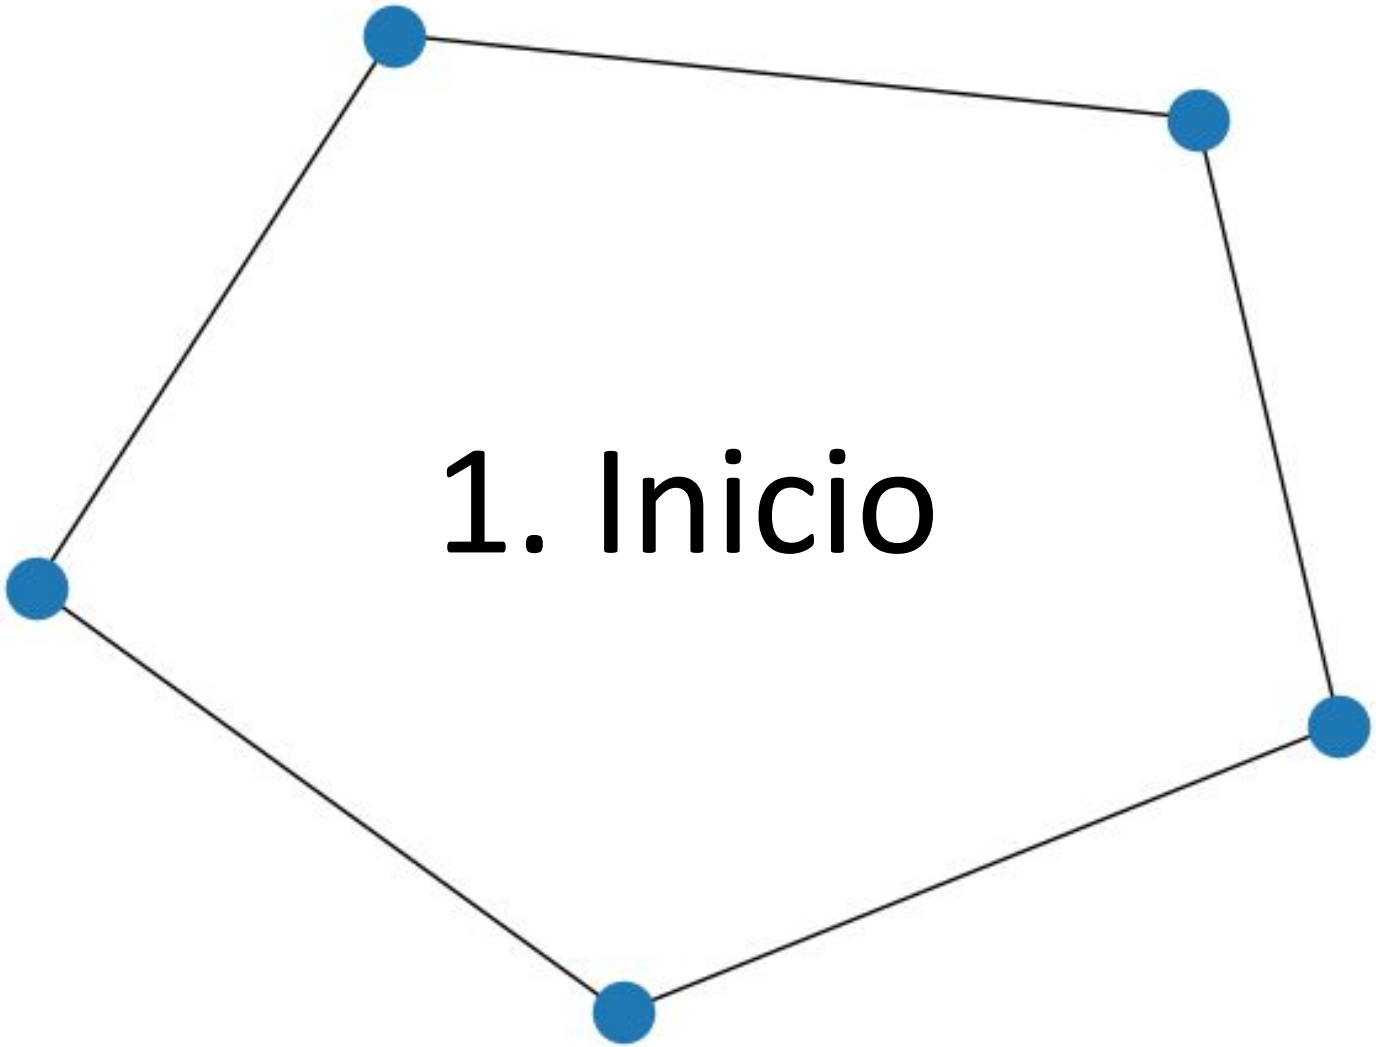
ANÁLISIS DE TRAYECTORIAS GENÉTICAS MEDIANTE **MAPAS DE DIFUSIÓN** PARA EL ESTUDIO DE LA **DIFERENCIACIÓN** CELULAR EN **GLIOBLASTOMA**

Índice

1. Inicio
    1. Introducción
    2. Objetivos
2. Desarrollo
    1. Preprocesamiento
    2. Pipeline
    3. Resultados
3. Cierre
    1. Conclusiones y trabajo a futuro



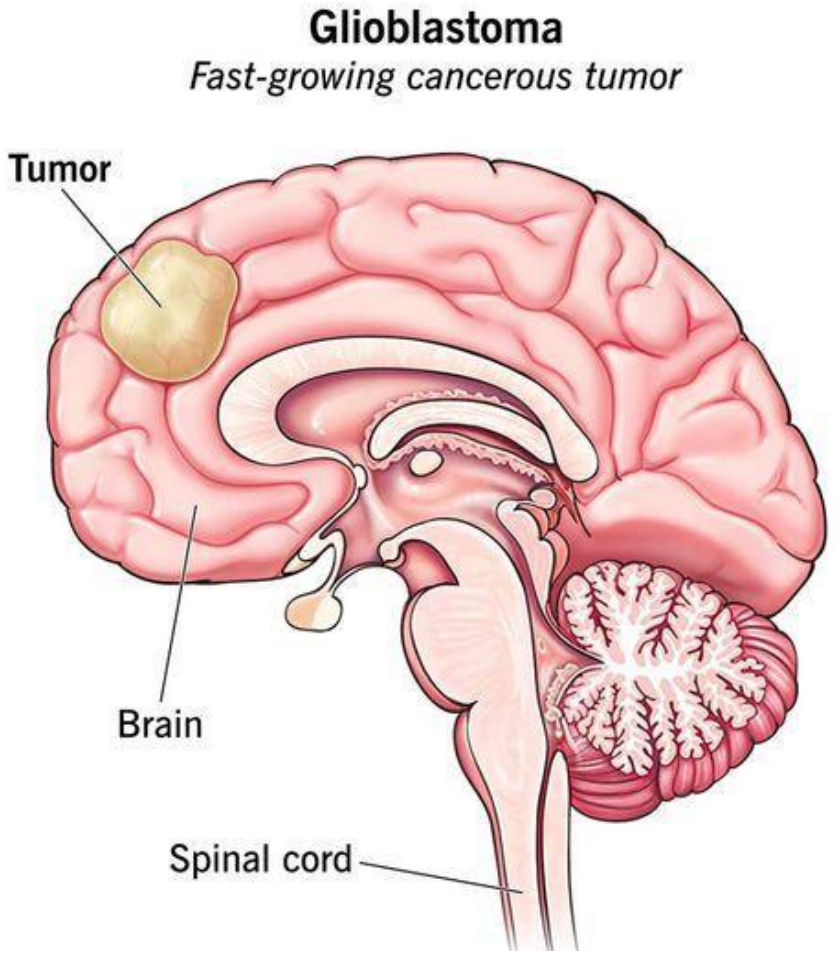


1. Inicio

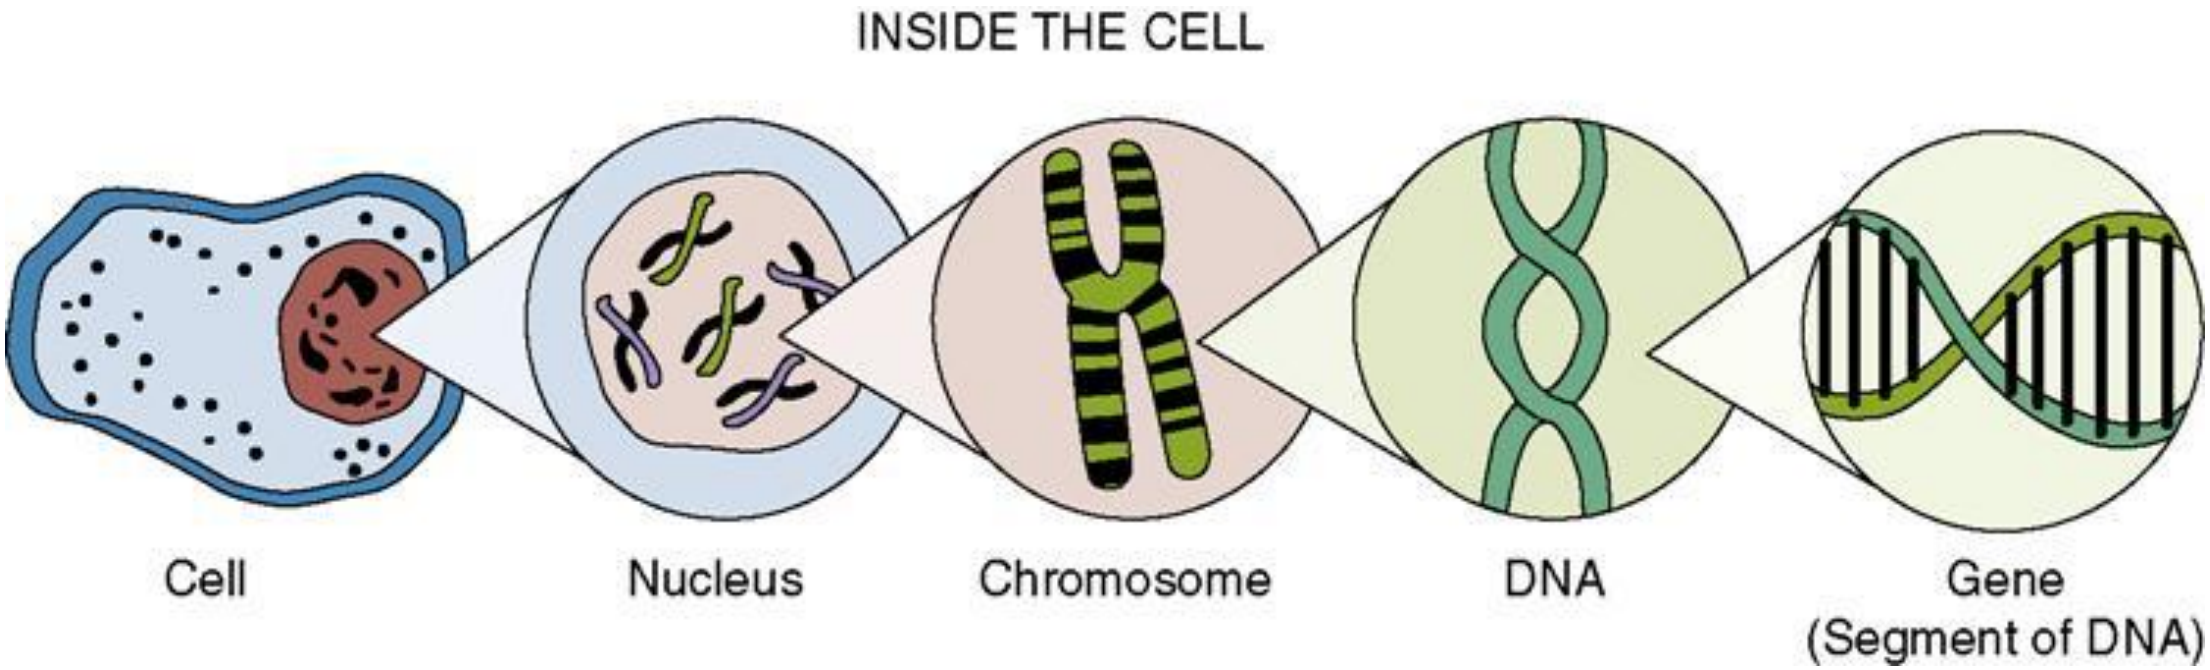
Introducción: Glioblastoma

- Tumor más común en adultos
- Agresivo
- Heterogéneo

} Difícil tratamiento

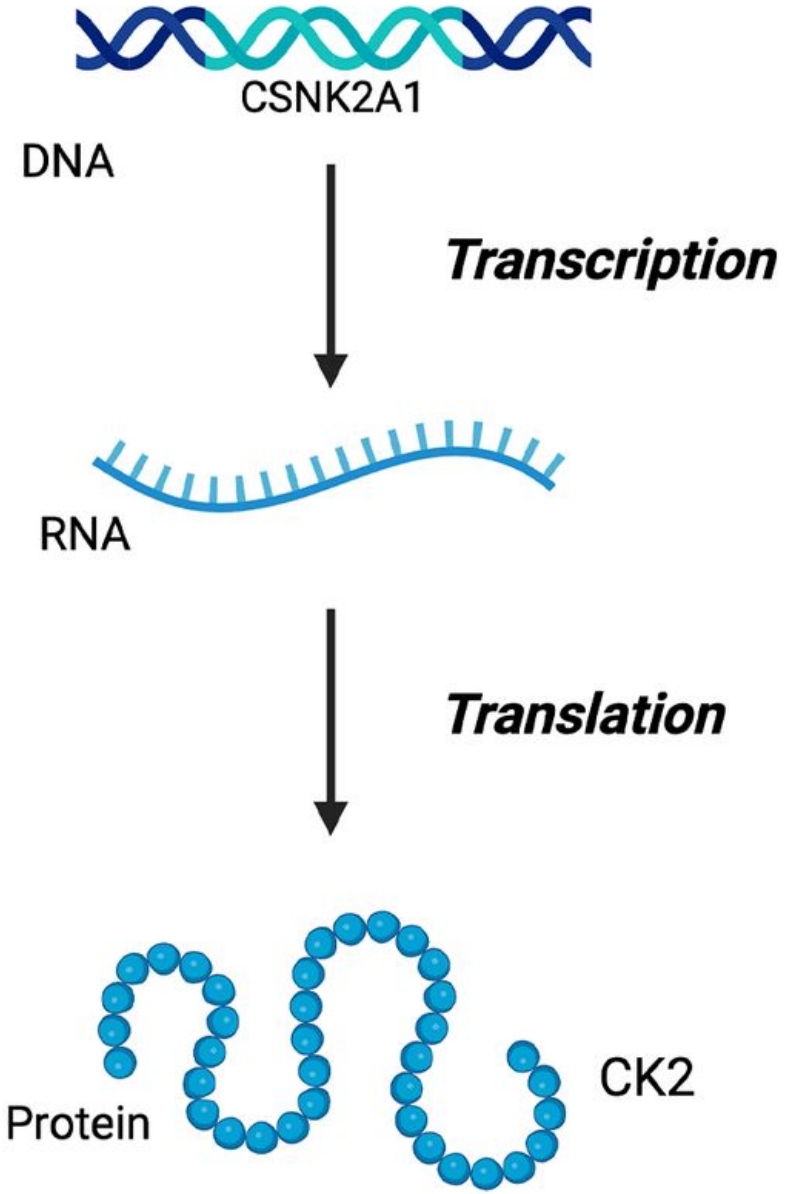


Introducción: ADN y genes



Introducción: Transcriptómica

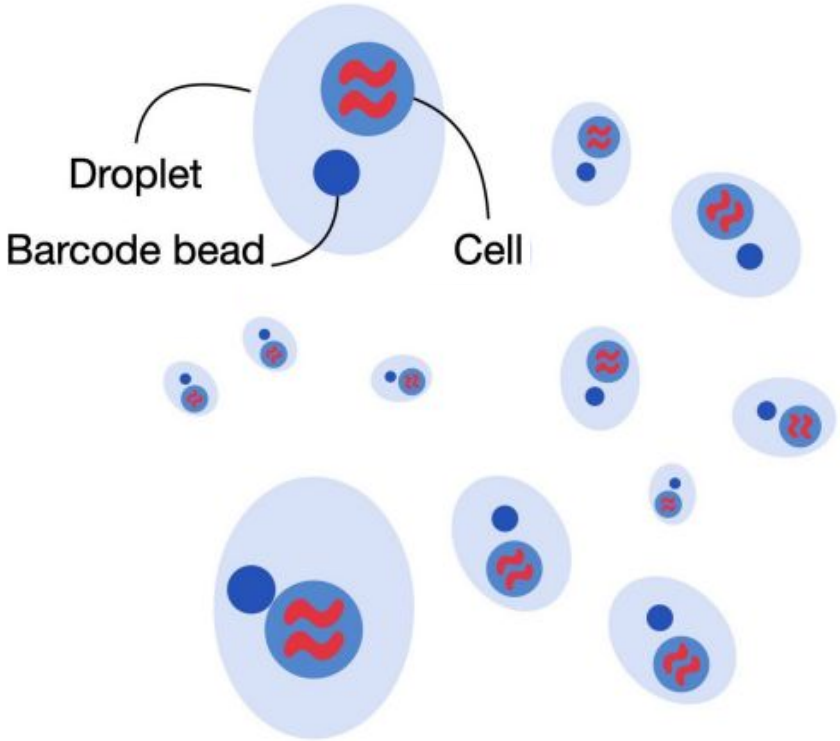
- La célula solo utiliza una parte de su ADN (genes)
- La transcriptómica mide que **genes** están siendo **utilizados**



Introducción: Secuenciación de ARN

- En un laboratorio se miden las moléculas de ARNm (“lecturas de genes”)

- Cuando se mide cada célula por separado decimos que es secuenciación “single cell”



Introducción: Matriz de expresión

- De medir ARN se obtiene una matriz de expresión (conteos) de genes

- Sobre la que se pueden hacer anotaciones

	Cell1	Cell2	…	CellN
Gene1	3	2	.	13
Gene2	2	3	.	1
Gene3	1	14	.	18
…	.	.	.	.
…	.	.	.	.
…	.	.	.	.
GeneM	25	0	.	0

Introducción: Perfil de expresión

- Muchas variables (alrededor de 20.000 genes)
- Muchos valores nulos (una célula no expresa todos los genes posibles)
- ¡Podemos pensar en células como vectores!

$$\begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix}$$



Lymphocyte



Monocyte

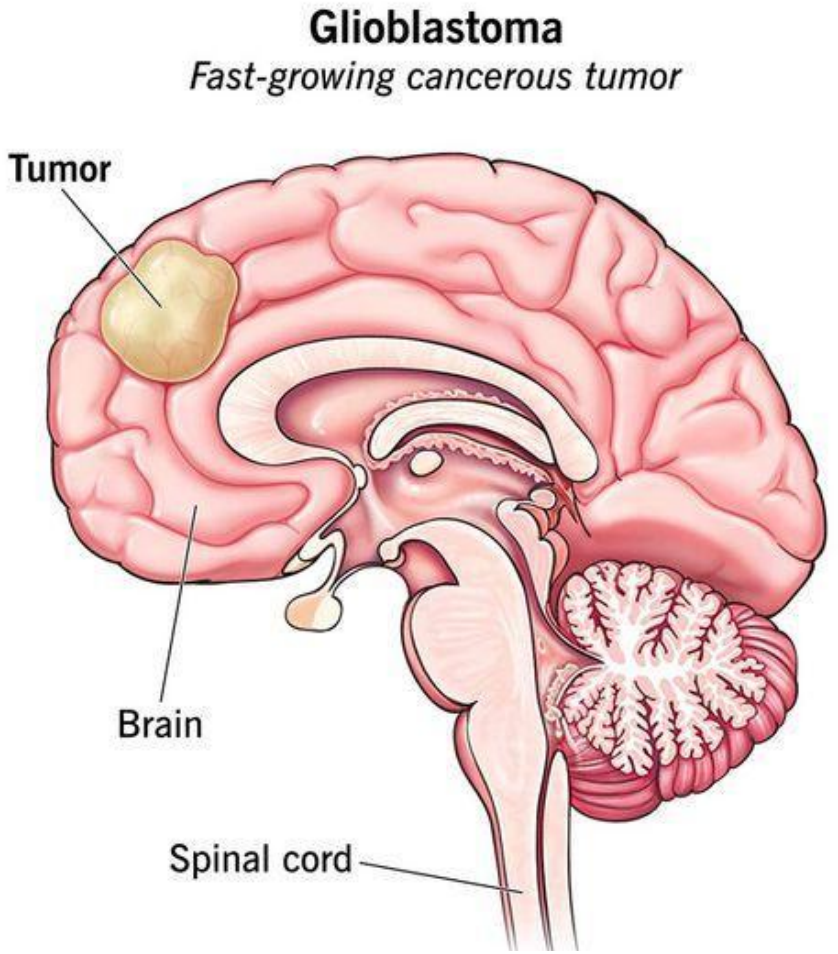
$$\begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_n \end{bmatrix}$$

Introducción: Pseudotiempo

Podemos cuantificar las células por los genes que expresan…

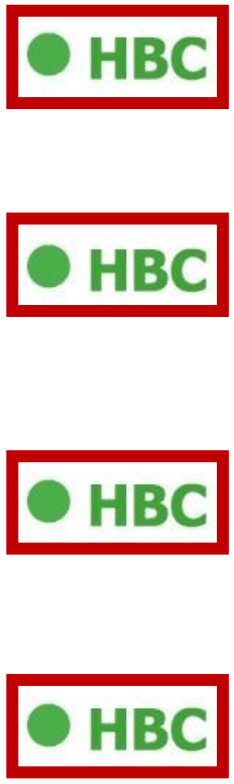
¿Y ahora qué?

Modelar diferenciación y/o división de las células tumorales



Introducción: Pseudotiempo

Células iniciales



scRNA-seq





Introducción: Señales biológicas

- Stemness Potencial para dividirse
- Senescencia Arresto del ciclo celular
- Estados tumorales Células conocidas parecidas
- Pseudotiempo Grado de “diferenciación”

Métricas que reflejan procesos biológicos reales

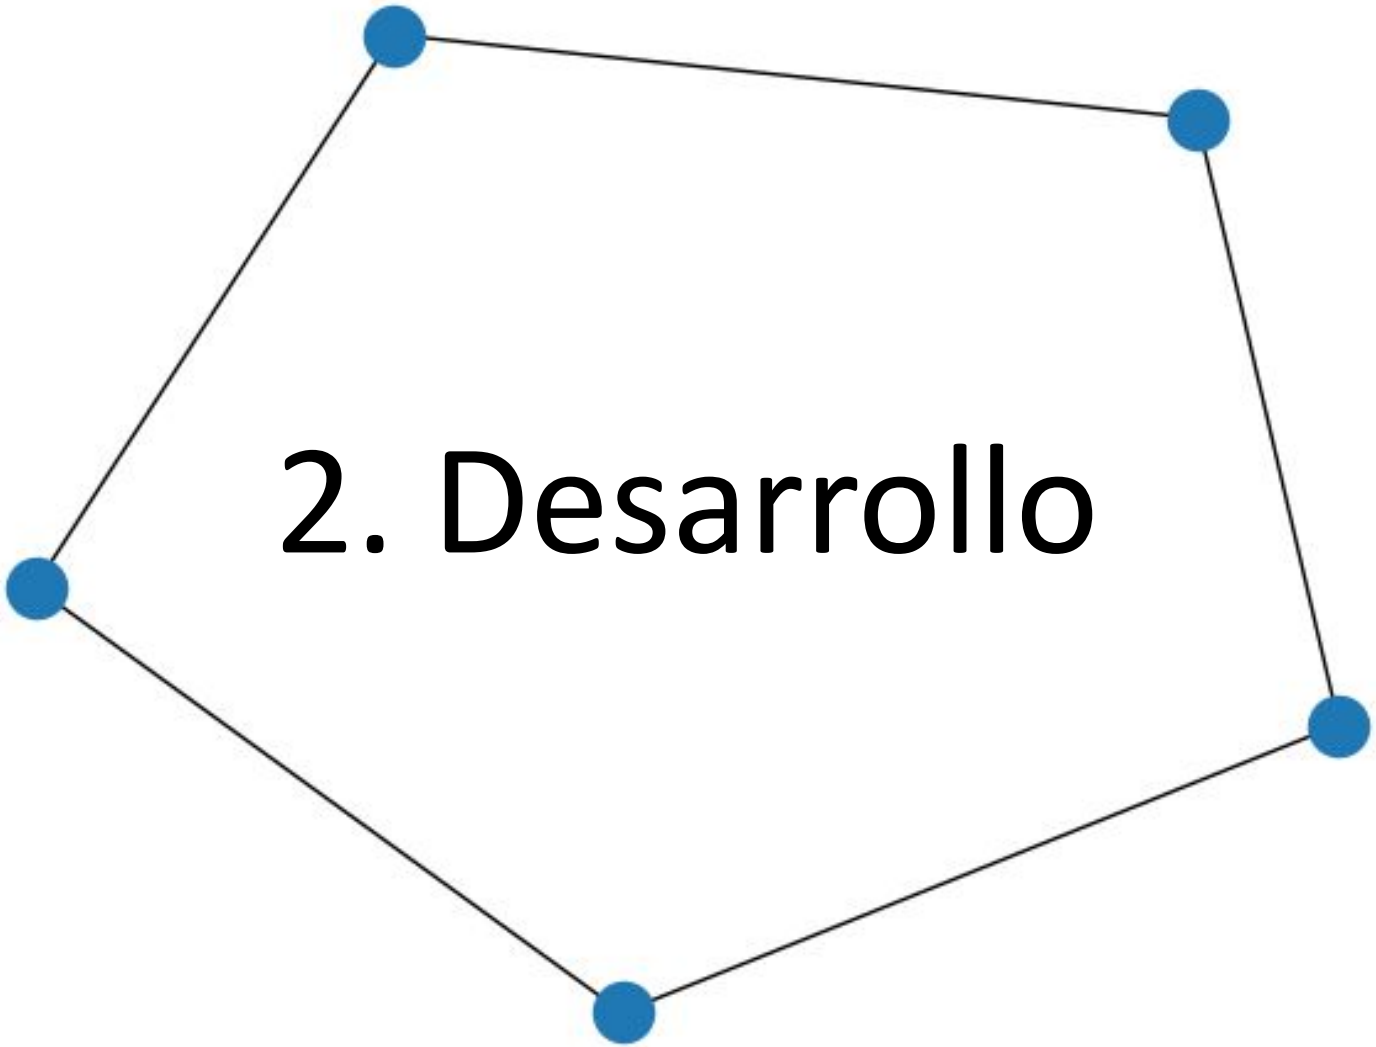
Objetivo general

Comprender mejor la enfermedad

- Analizar relación entre propagación de la información genética (pseudotiempo) y factores biológicos

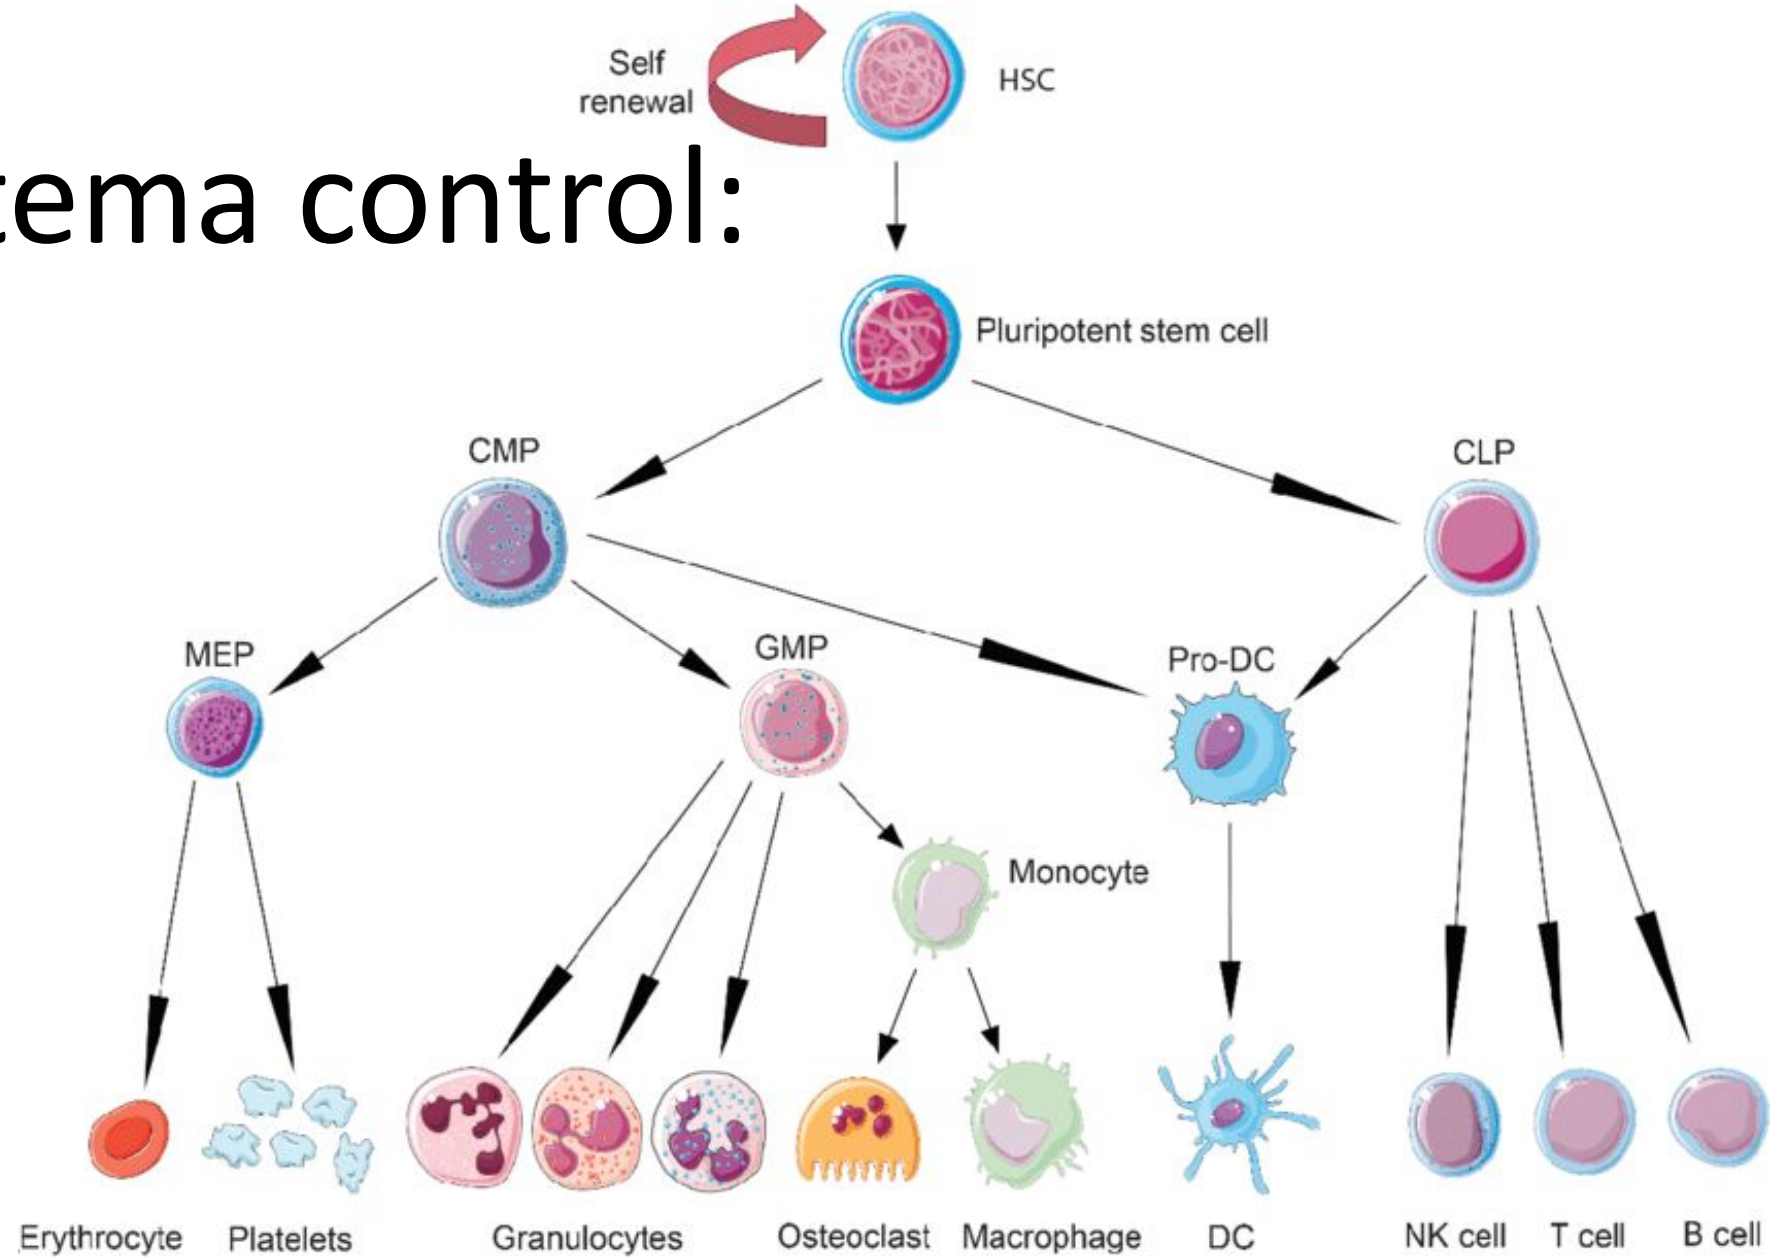
- Definir un pipeline que transforme datos a una representación interpretable





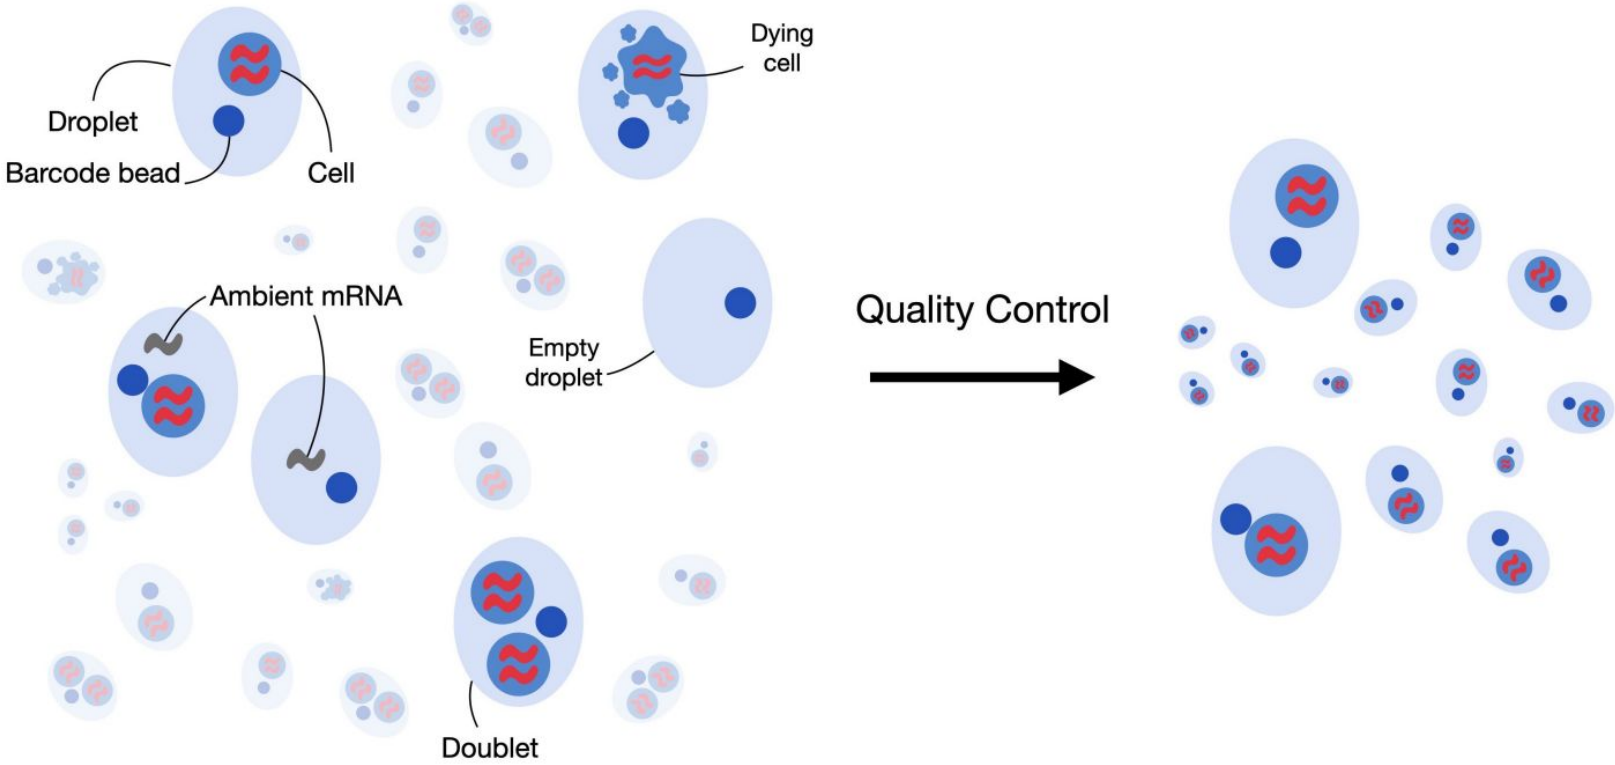
2. Desarrollo

Sistema control:

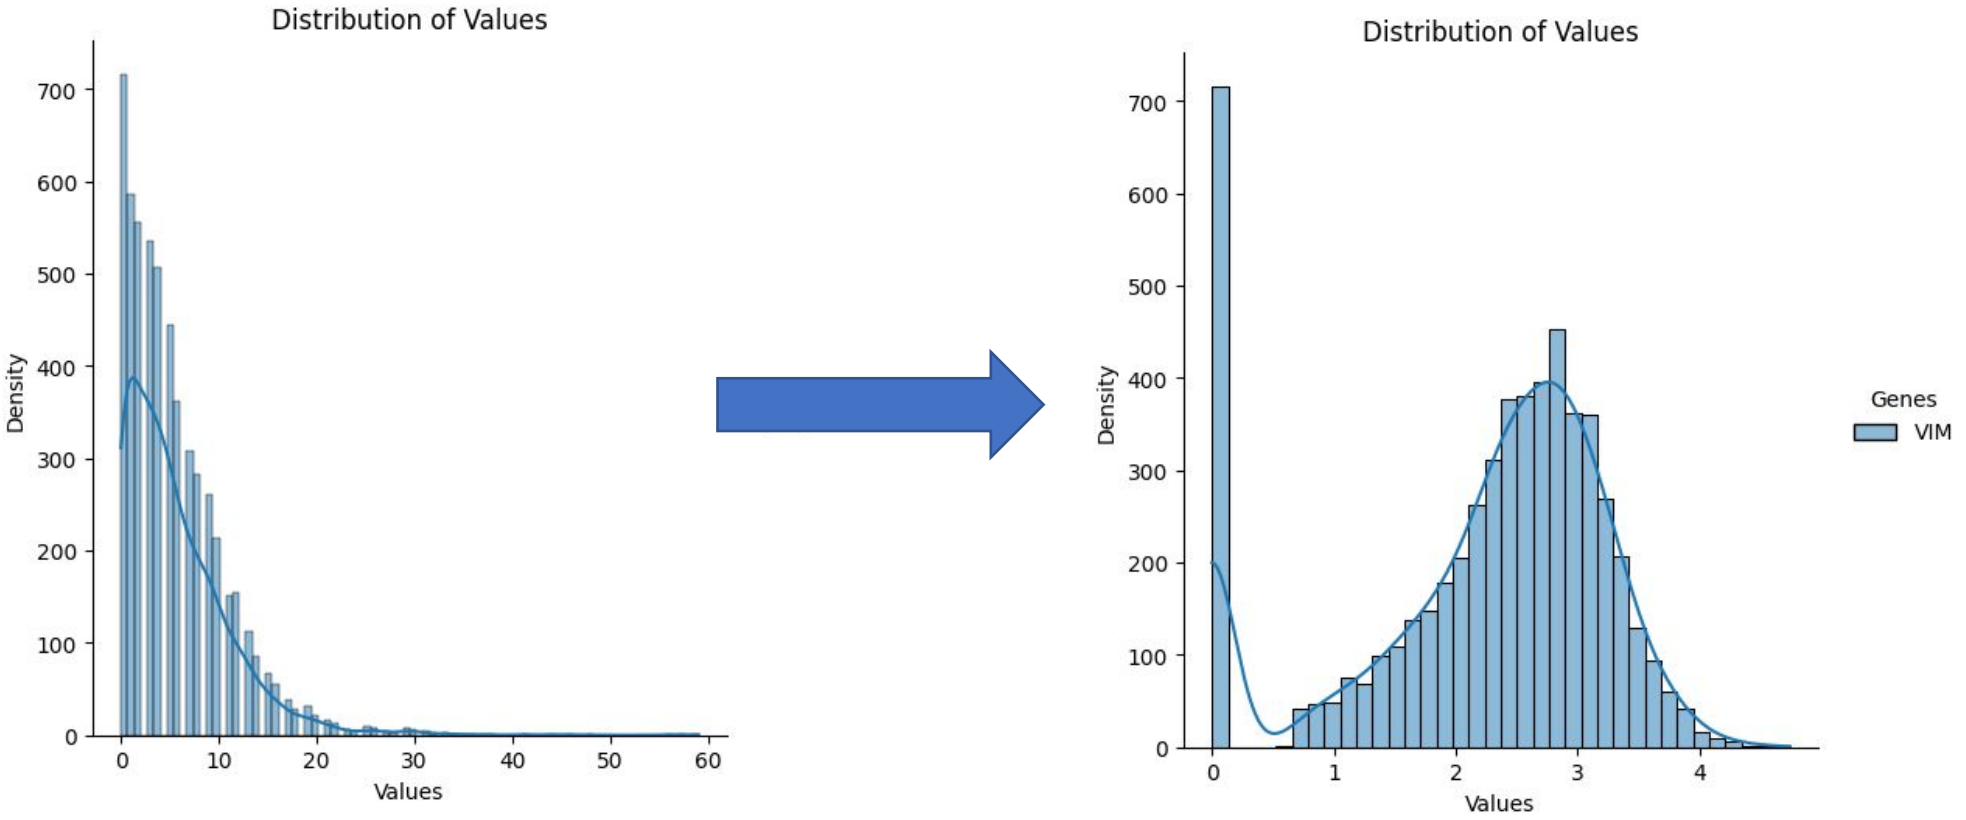


Preprocesamiento: Control de calidad

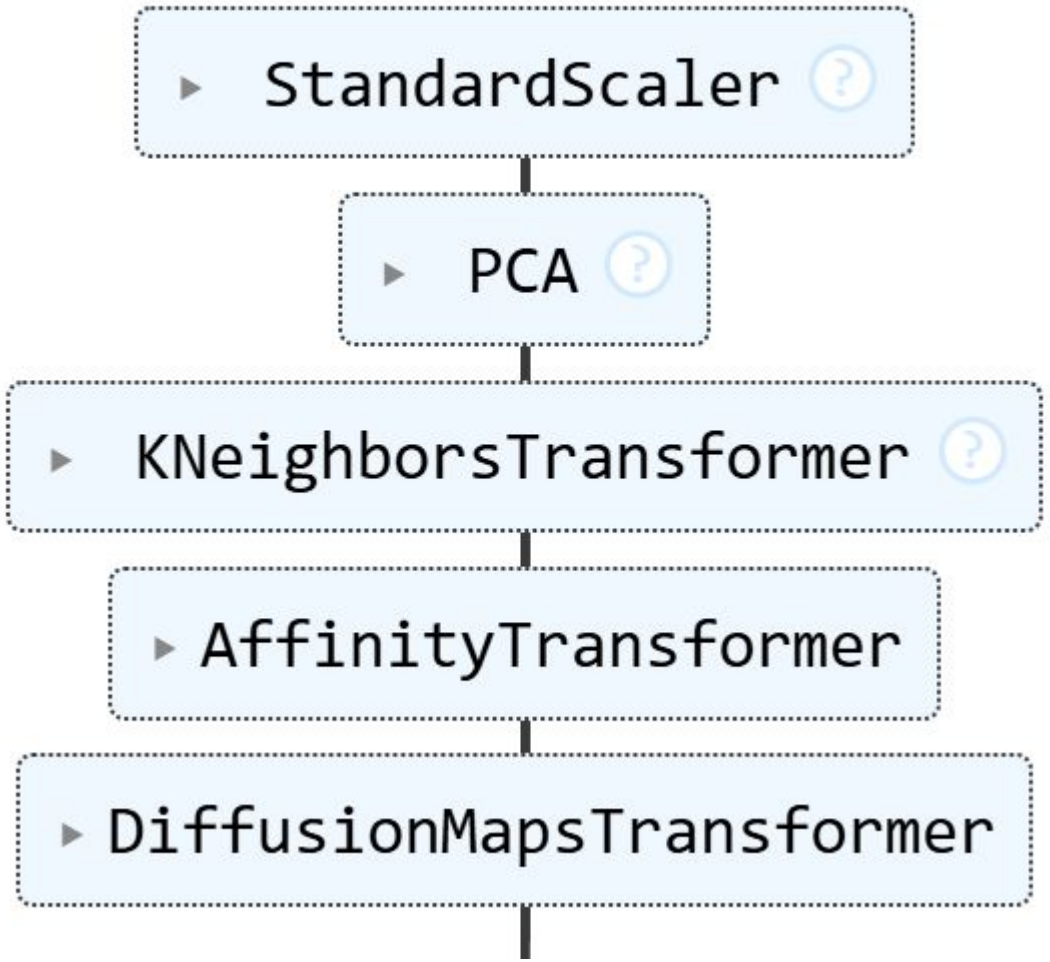
- Se filtran células con números de cuentas anómalos y genes raros



Preprocesamiento: Normalizar y log1p



Pipeline



n

d, k

γ

α, t, n

Hiperparámetros



Pipeline: Escalado estándar (Z-Score)

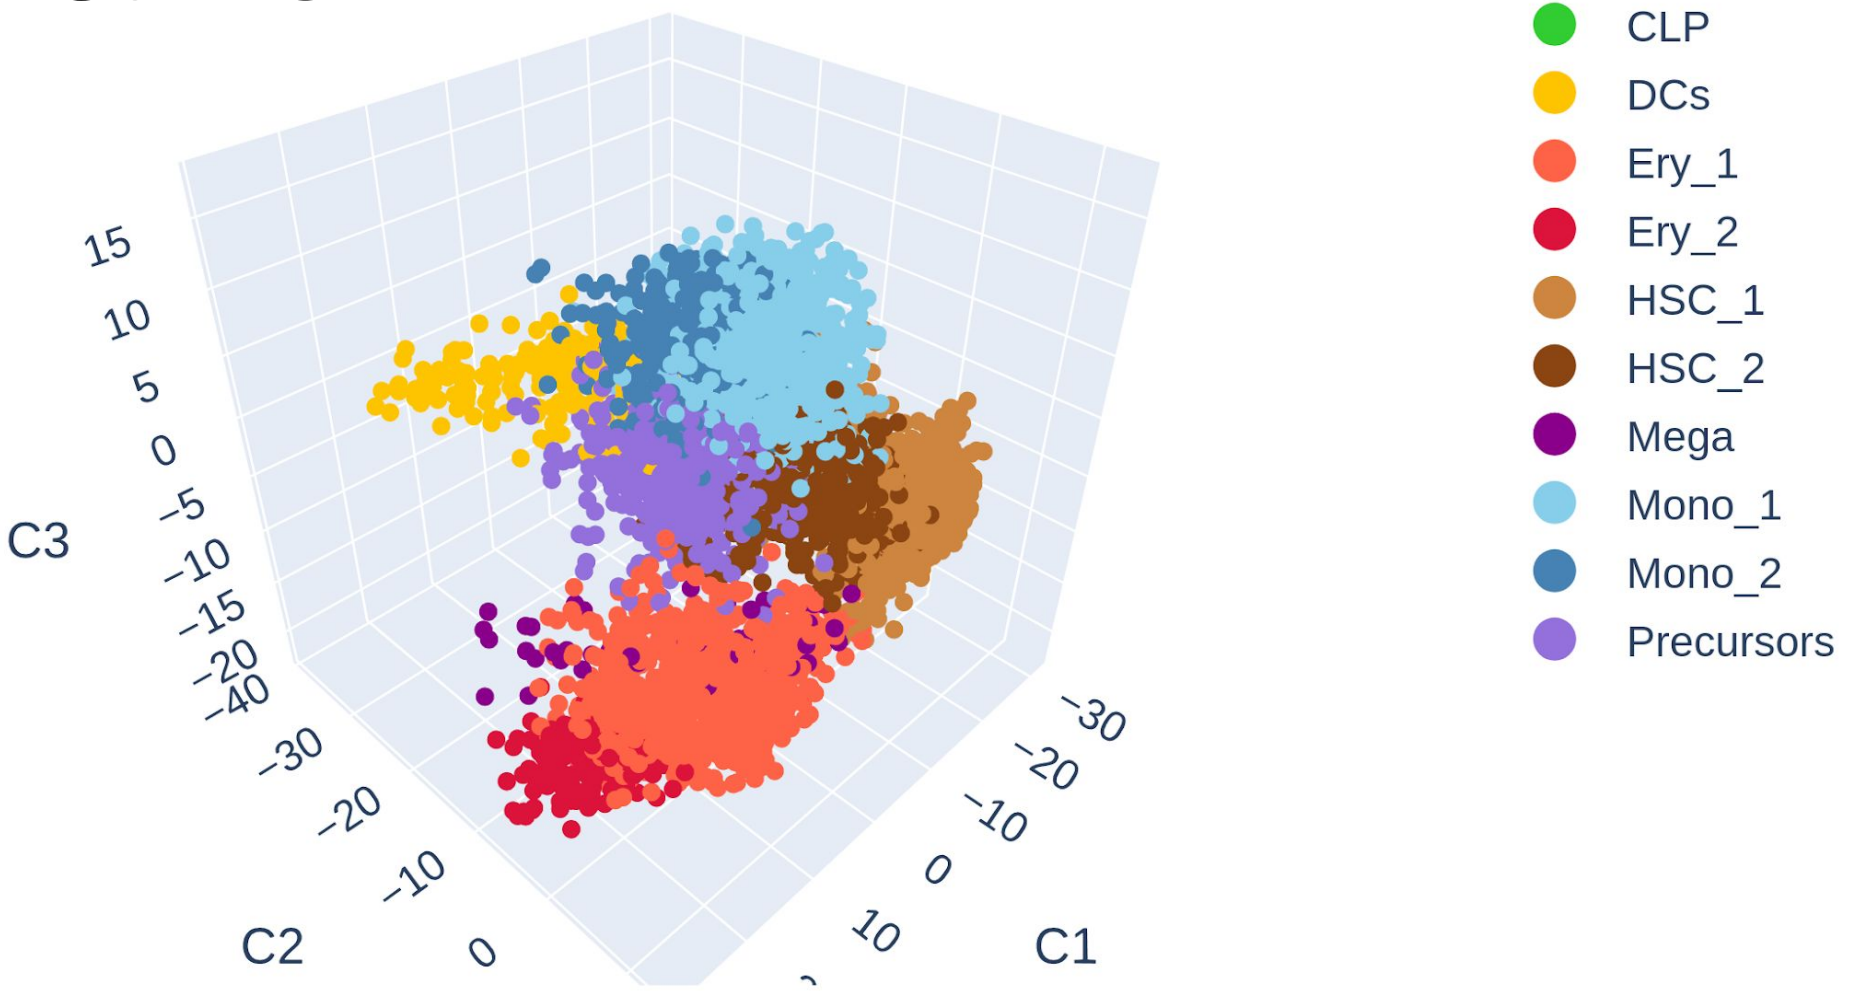
Transformación necesaria antes de PCA:

- Restar la media (centrar en cero) 

$$z_i = \frac{x_i - \mu}{\sigma}$$

- Escalar a desviación la unidad

Pipeline: PCA

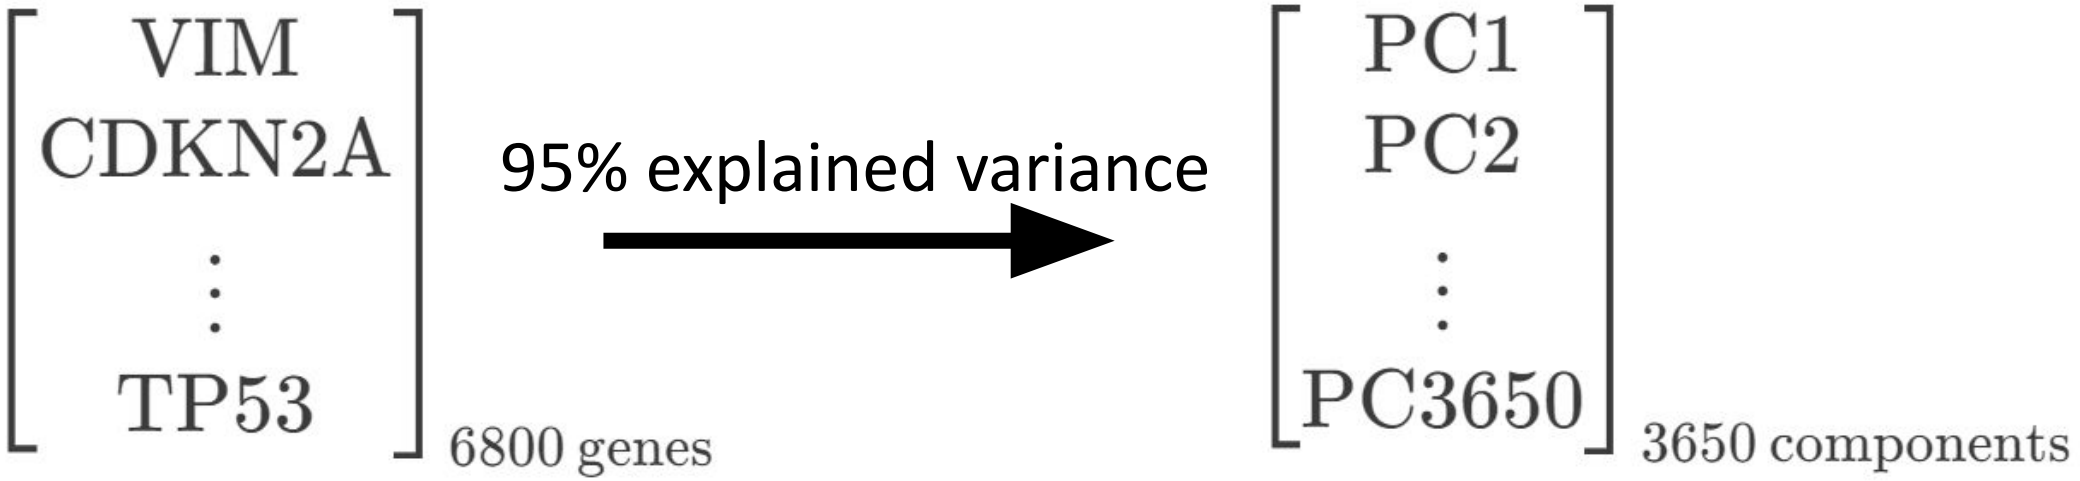


Pipeline: PCA

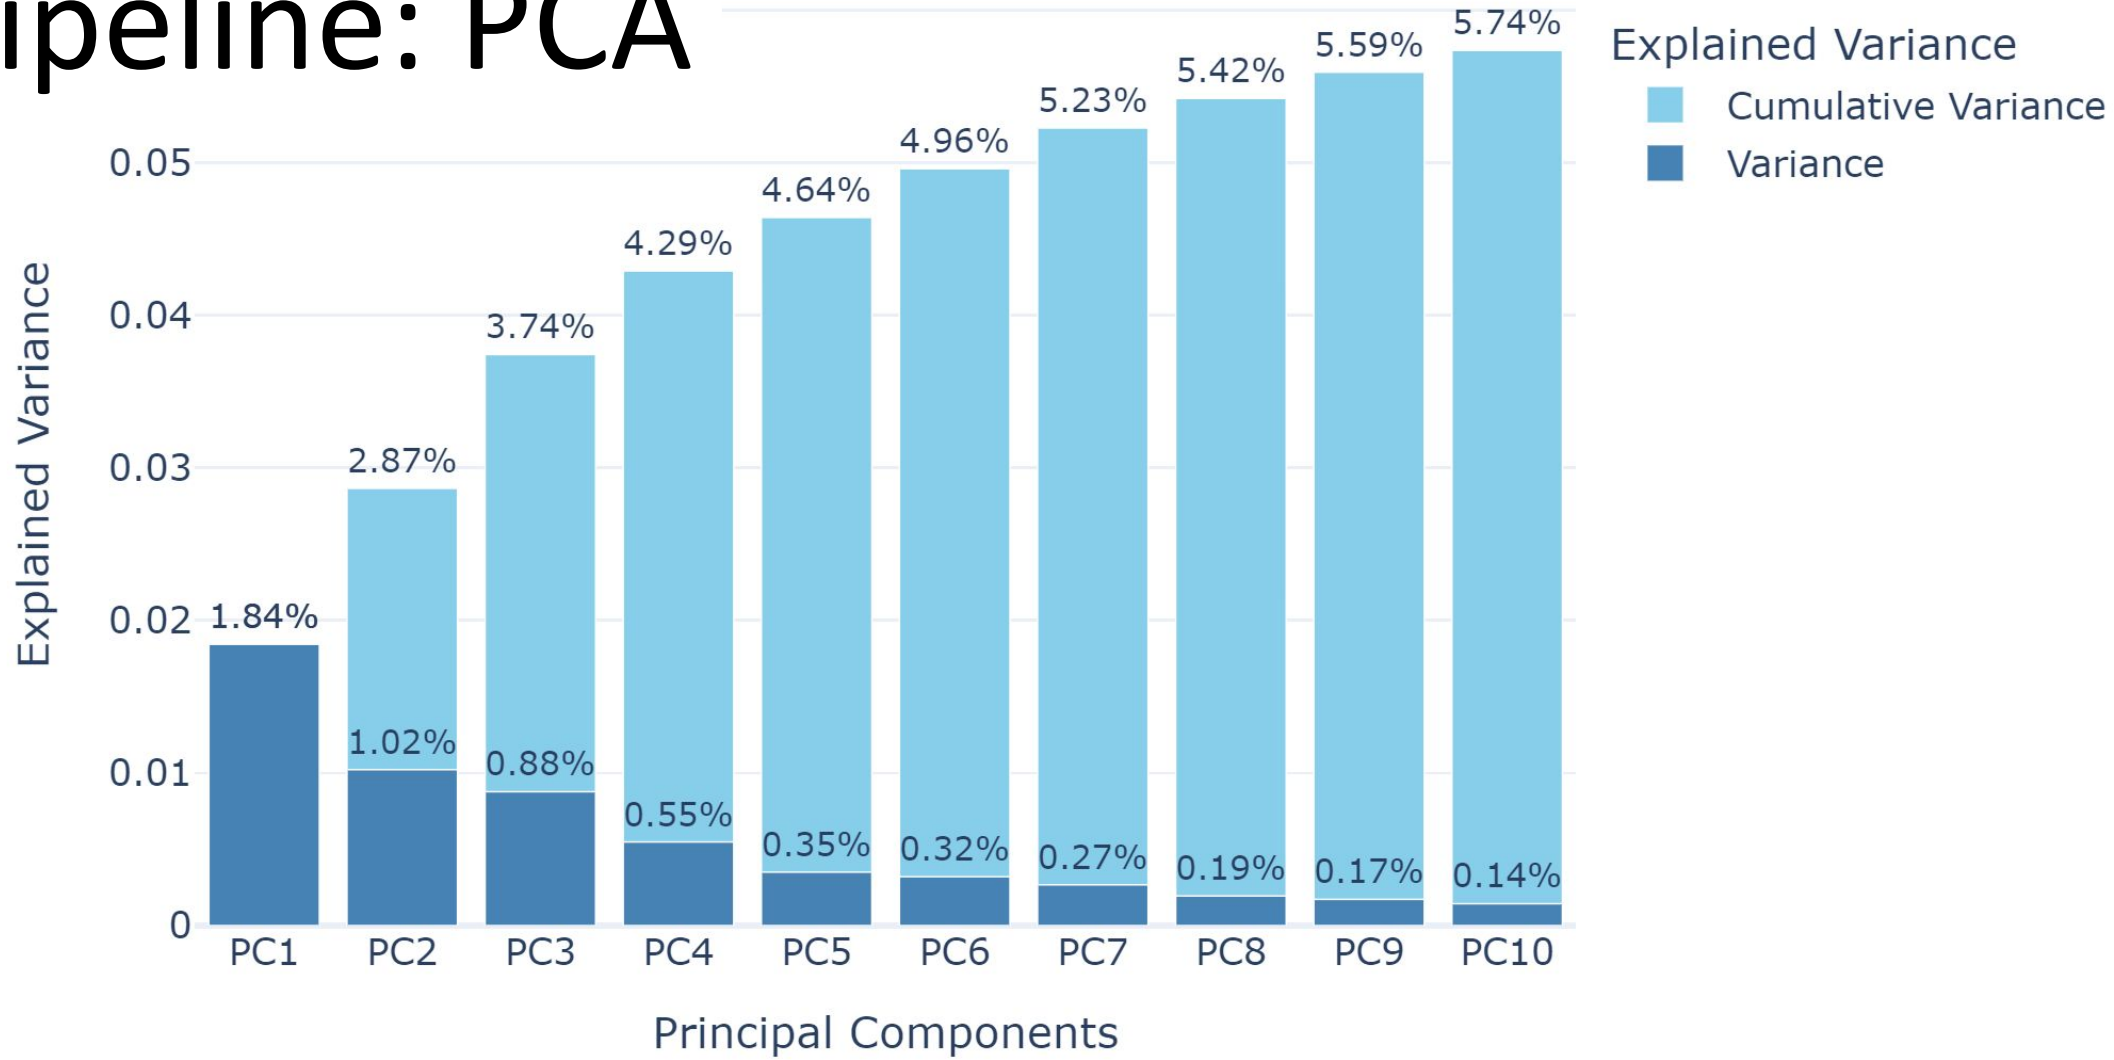
Hiperparámetros relevantes:

- ¿Número de componentes principales?

 Suficientes para explicar el 95% de la varianza



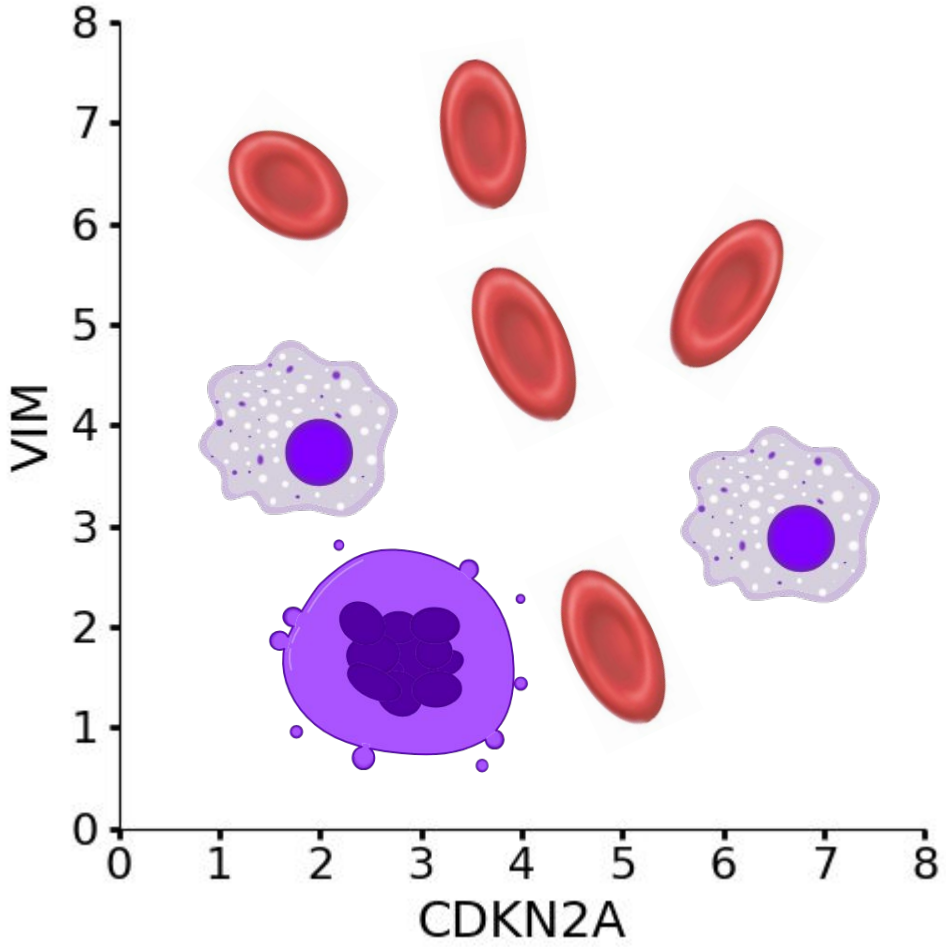
Pipeline: PCA



Herramienta: Grafo de similitud

Se asume que:

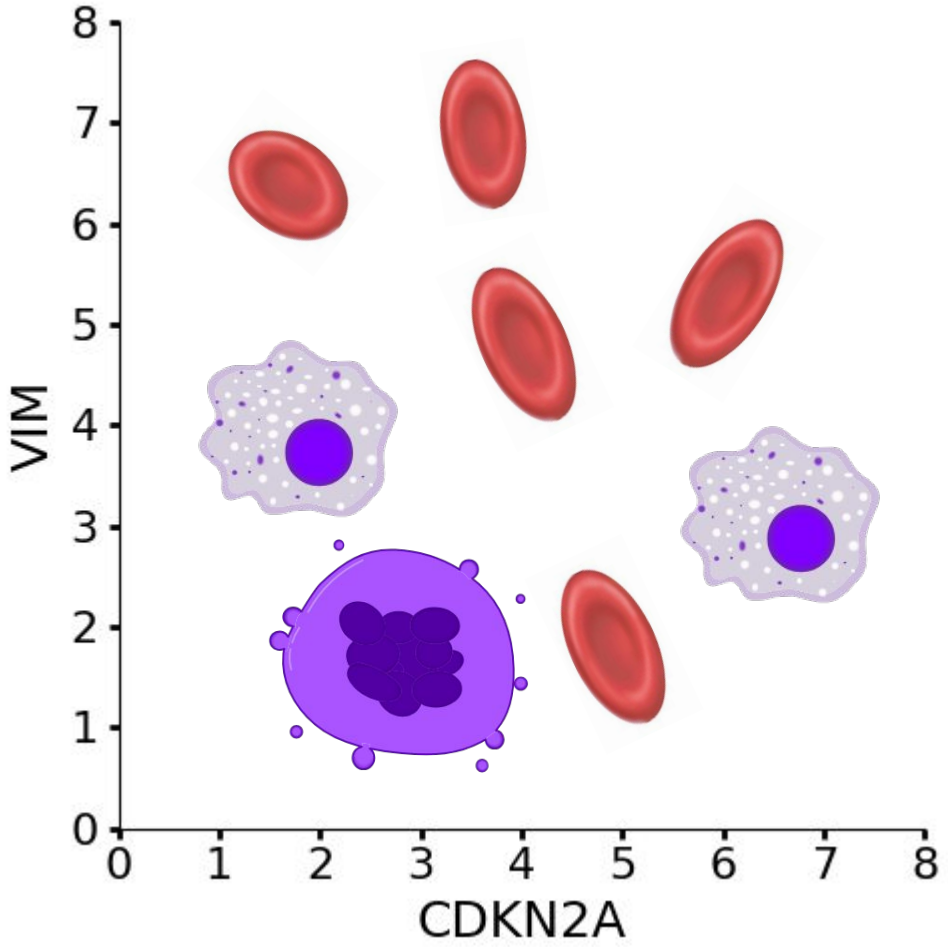
- La diferenciación es un proceso continuo
- Células “similares” estarán cerca en el proceso de diferenciación



Herramienta: Grafo de similitud

Grafo con el par:

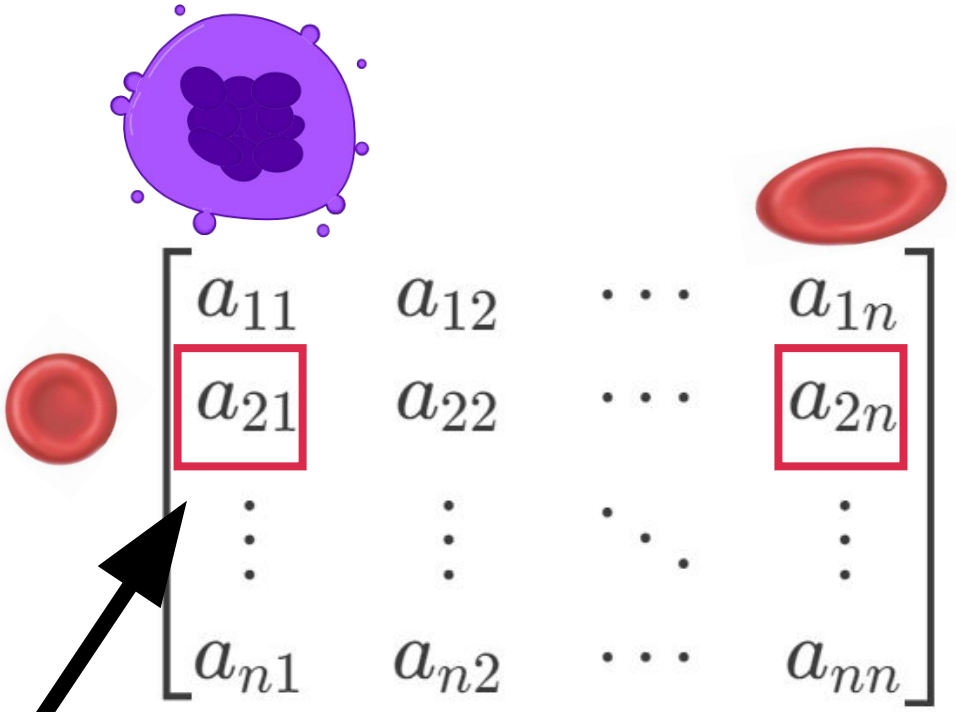
- Conjunto de nodos: células



Herramienta: Grafo de similitud

Grafo con el par:

- Conjunto de nodos: células
- Conjunto de aristas (matriz): “similitud” entre nodos



Similitud entre célula 2 y célula 1

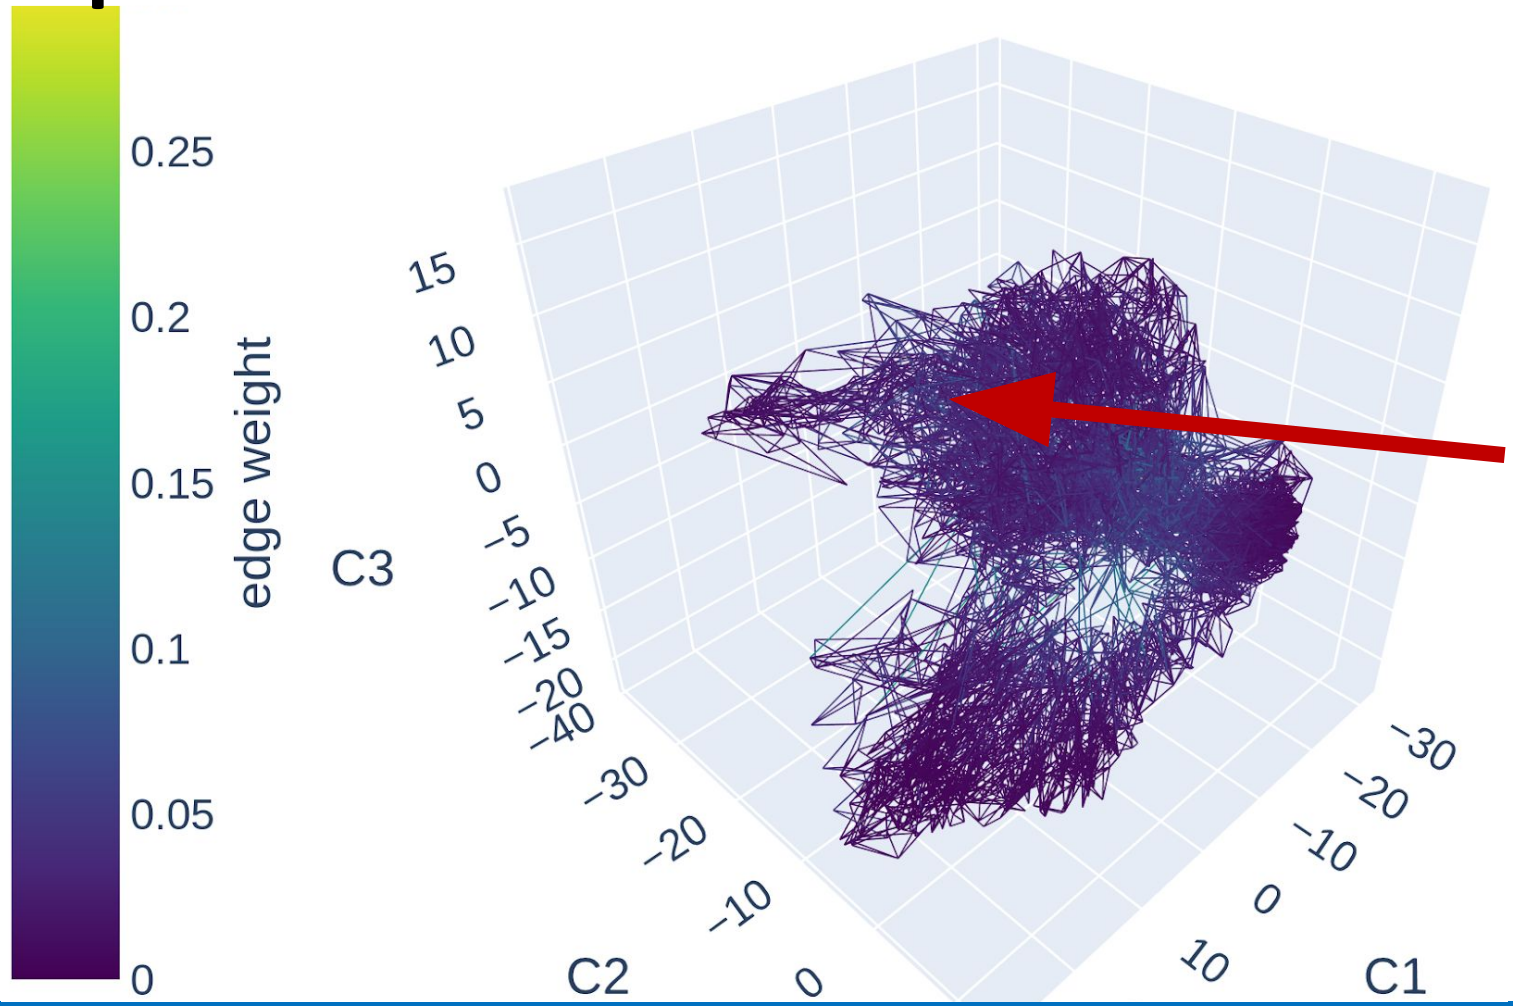
Pipeline: KNN

- Se crean aristas entre las k células más parecidas
- Representamos las aristas con una matriz de similitud/distancia

$$W = \begin{pmatrix} w_{11} & \cdots & w_{1j} & \cdots & w_{1n} \\ \vdots & \ddots & & & \vdots \\ w_{i1} & & w_{ij} & & w_{in} \\ \vdots & & & \ddots & \vdots \\ w_{n1} & \cdots & w_{nj} & \cdots & w_{nn} \end{pmatrix}$$

Similitud entre célula **i** y célula **j**

Pipeline: KNN



Similitud entre la célula **i** y la célula **j**

Pipeline: KNN

Hiperparámetros relevantes:

- ¿Métrica de similitud?

 Distancia coseno $\mathrm{d}_{\cos}(\mathbf{u}, \mathbf{v}) = 1 - \dfrac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}$

- ¿Número de vecinos cercanos?

 2% del total de células 

Pipeline: Afinidad y operador difusión

- Se convierten distancias en “probabilidades” (kernel)

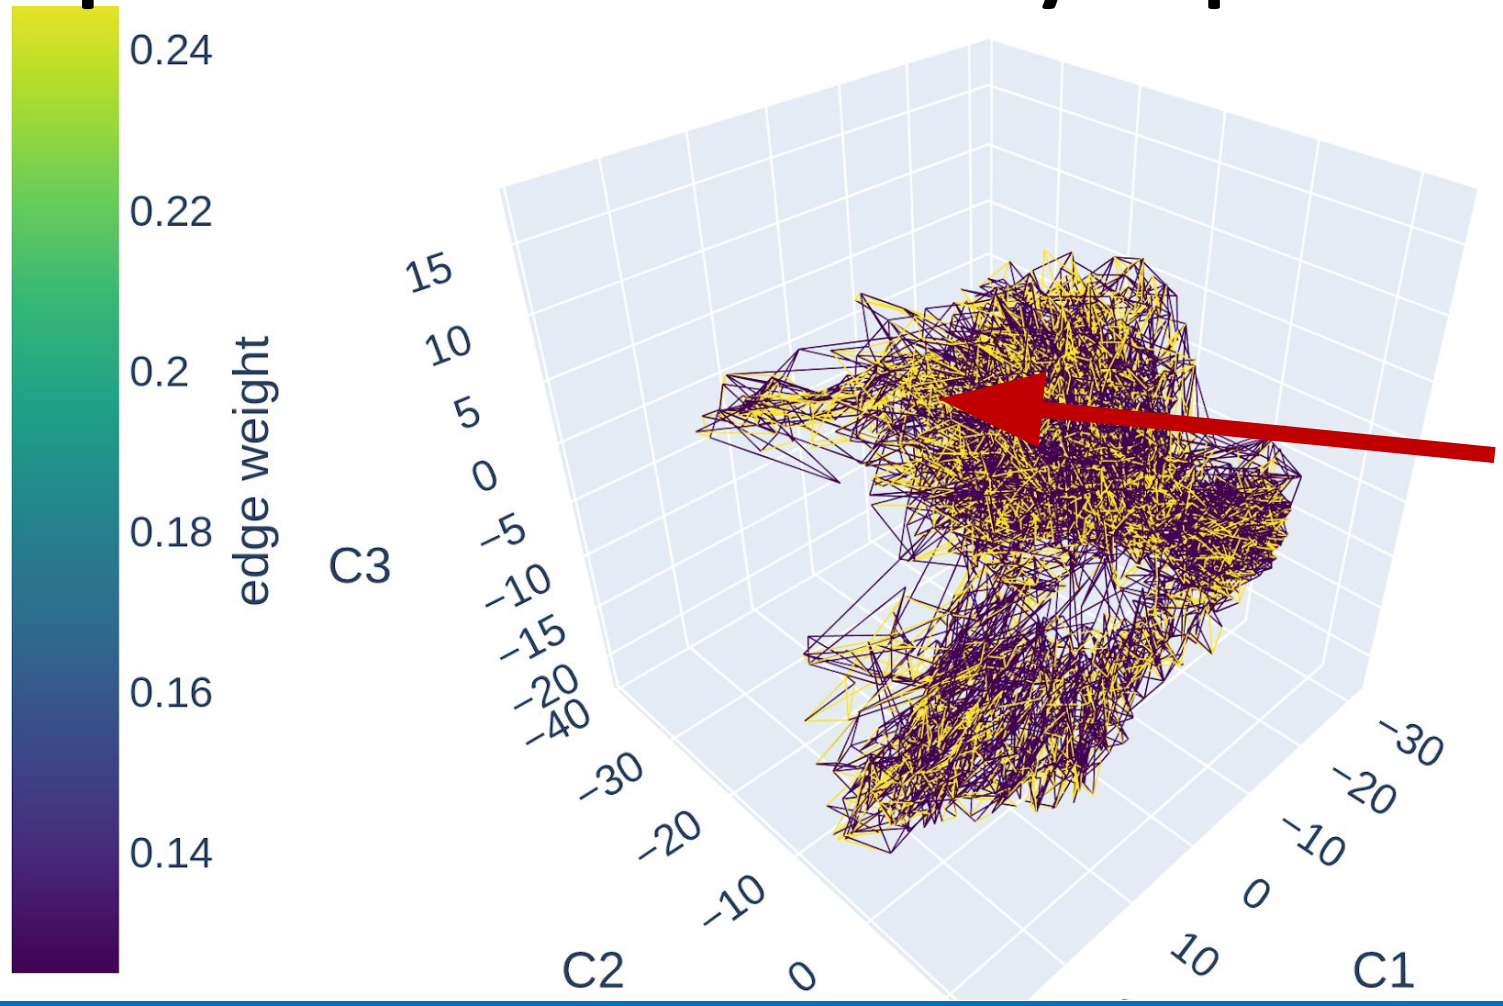
$$W \rightarrow W'$$

- Se normaliza para conseguir un operador de difusión (matriz)

$$P_{rw} = D^{-1} \cdot W'$$

$$P_{sym} = D^{-1/2} \cdot W' \cdot D^{-1/2}$$

Pipeline: Afinidad y operador difusión



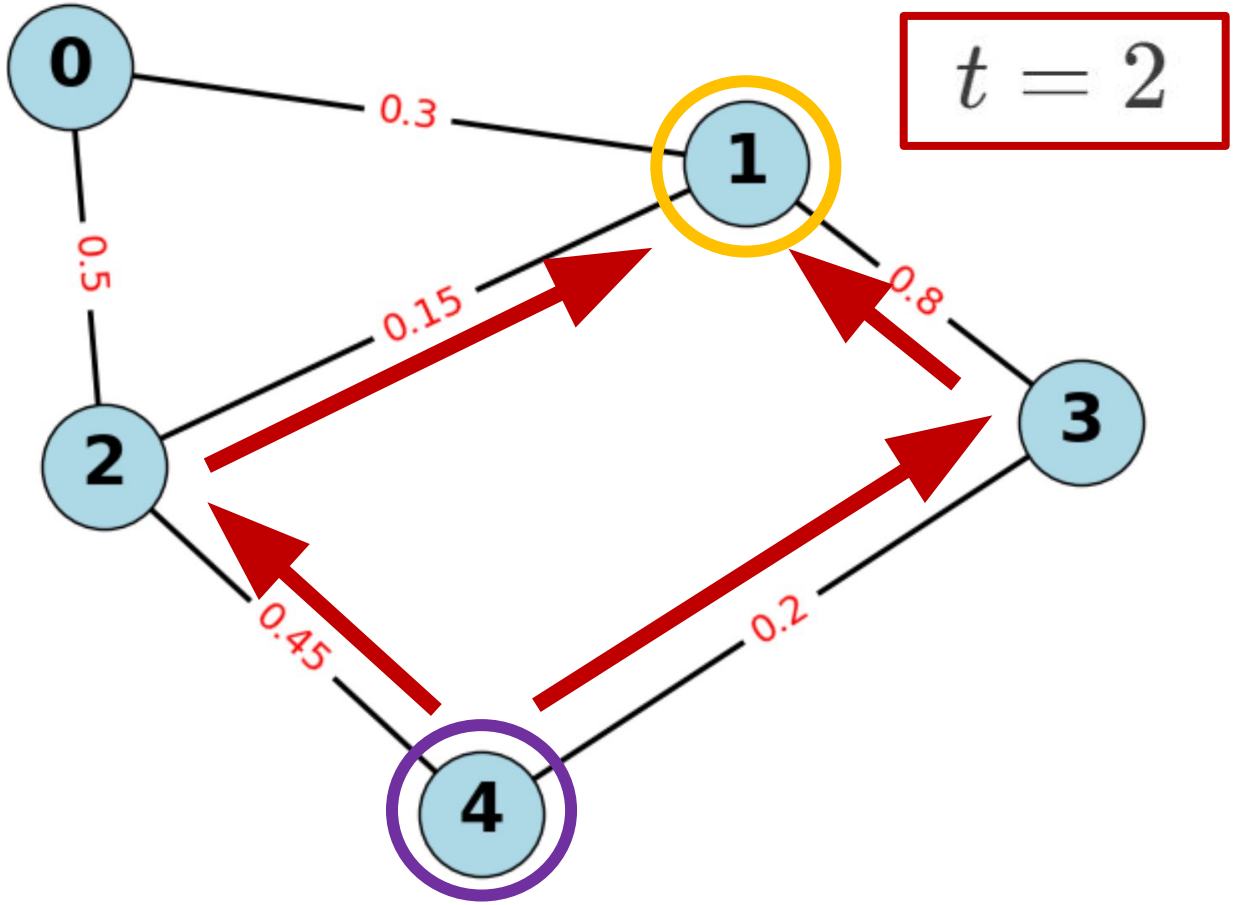
Probabilidad de transicionar de la célula **i** a la célula **j**

Herramienta: Caminos aleatorios

En un grafo de probabilidades:

- Podemos transicionar entre nodos usando las reglas de probabilidad en **t** pasos

- Se define distancia de difusión entre nodos como métrica de conectividad



Herramienta: Caminos aleatorios

Distancia de difusión:

- Probabilidad alta de transicionar Distancia de difusión pequeña

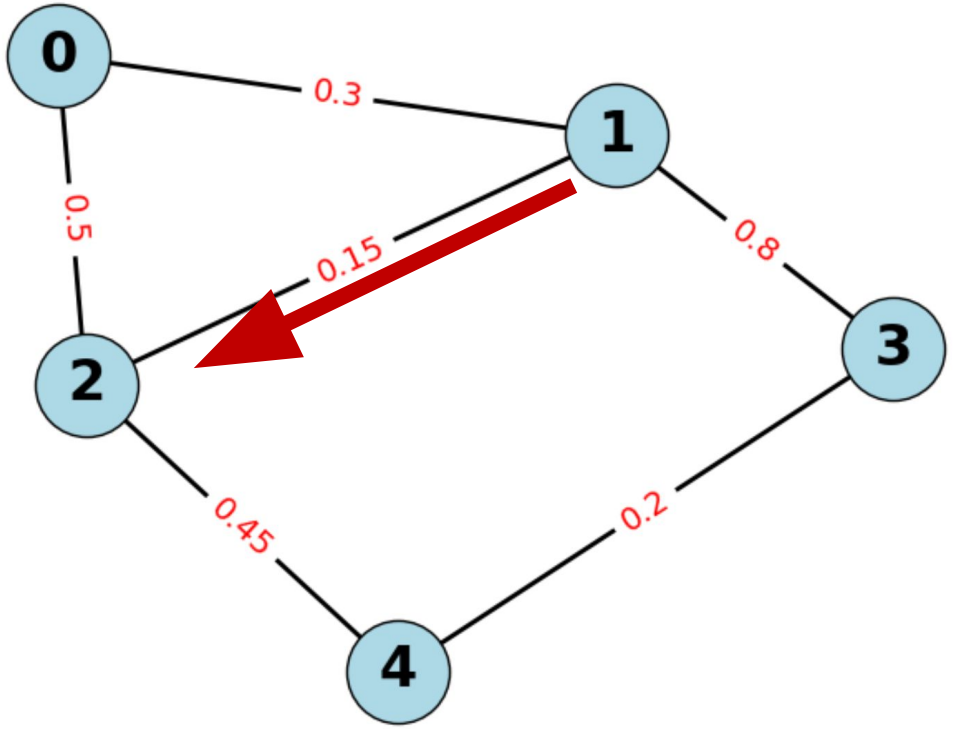
- Probabilidad baja de transicionar Distancia de difusión grande

$$D_t^2(i,j) = \sum_k \frac{(p_t(i,k) - p_t(j,k))^2}{\phi(k)}$$

Herramienta: Caminos aleatorios

- Camino aleatorio de 1 paso

$$P^1 = \begin{pmatrix} 0 & 0.3 & 0.5 & 0 & 0 \\ 0.3 & 0 & 0.15 & 0.8 & 0 \\ 0.5 & 0.15 & 0 & 0 & 0.45 \\ 0 & 0.8 & 0 & 0 & 0.2 \\ 0 & 0 & 0.45 & 0.2 & 0 \end{pmatrix}$$

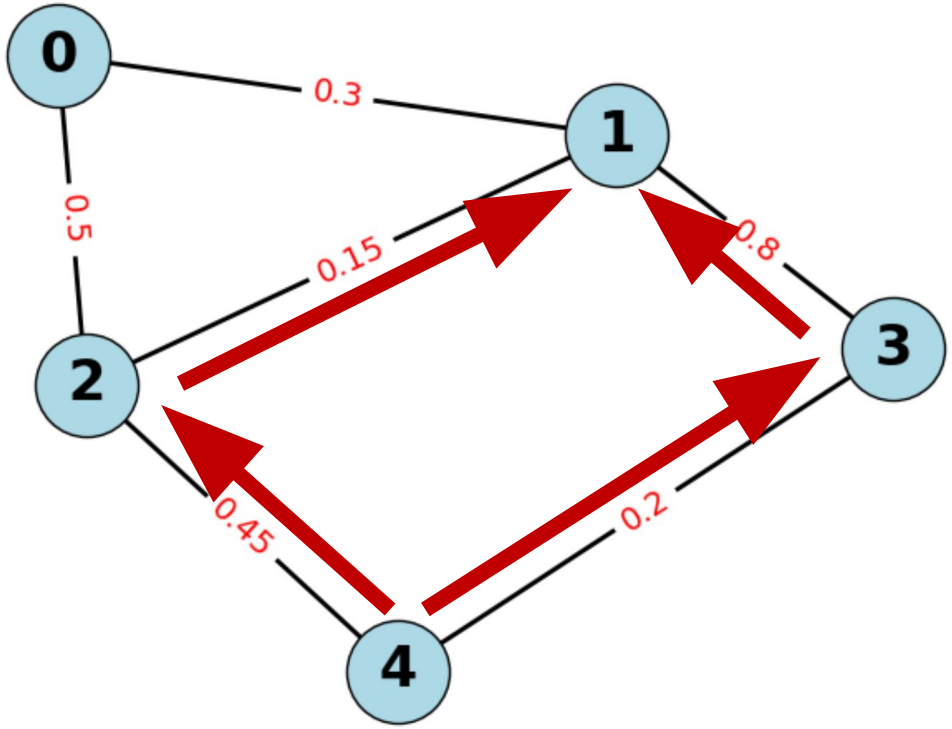


Probabilidad de transicionar de **1** a **2** en 1 paso

Herramienta: Caminos aleatorios

- n pasos □ Probabilidad condicionada

$$P^2 = \begin{pmatrix} 0.34 & 0.075 & 0.045 & 0.24 & 0.225 \\ 0.075 & 0.7525 & 0.15 & 0 & 0.2275 \\ 0.045 & 0.15 & 0.475 & 0.21 & 0 \\ 0.24 & 0 & 0.21 & 0.68 & 0 \\ 0.225 & 0.2275 & 0 & 0 & 0.2425 \end{pmatrix}$$



Probabilidad de transicionar de **4** a **1** en 2 pasos

Pipeline: Mapas de difusión

Distancia de difusión:

- También se puede expresar con vectores propios (ψ) y valores propios (λ) de un operador de difusión

$$D_t^2(x_i, x_j) = \sum_{l=1}^{\infty} \lambda_l^{2t} \left(\psi_l(x_i) - \psi_l(x_j)\right)^2$$

- Los podemos obtener de nuestro operador de difusión

Pipeline: Mapas de difusión

- Podemos representar nuestros datos en un espacio de difusión:

$$\Phi_t(i) = \left(\lambda_1^t \psi_1(i),\, \lambda_2^t \psi_2(i),\, \ldots,\, \lambda_d^t \psi_d(i)\right)$$

- ¡La distancia euclídea en este espacio aproxima distancia de difusión!

$$D_t(i,j)^2 \approx \left\|\Phi_t(i) - \Phi_t(j)\right\|^2$$

Pipeline: Mapas de difusión

En este espacio:

- Alta conectividad Distancia euclídea pequeña
- Baja conectividad Distancia euclídea grande

¡Interpretable!

Pipeline: Mapas de difusión

Hiperparámetros relevantes:

- ¿Número de componentes?

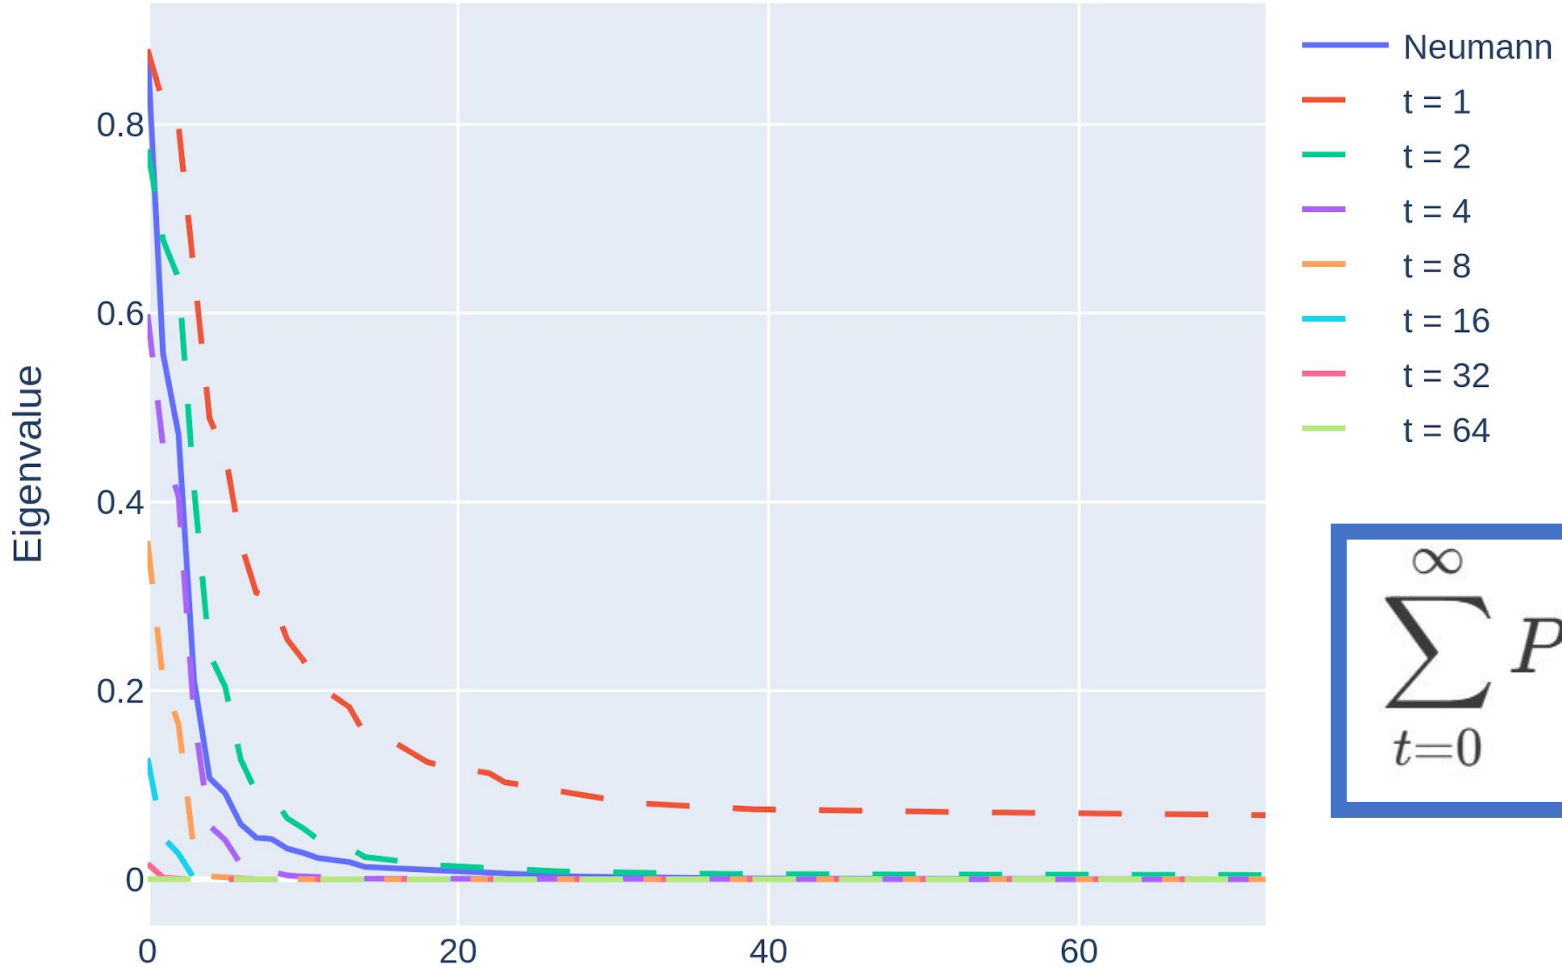
 Autovalores mayores que 0.05 

- ¿Número de pasos (**t**) en el grafo?

 Serie de Neuman 

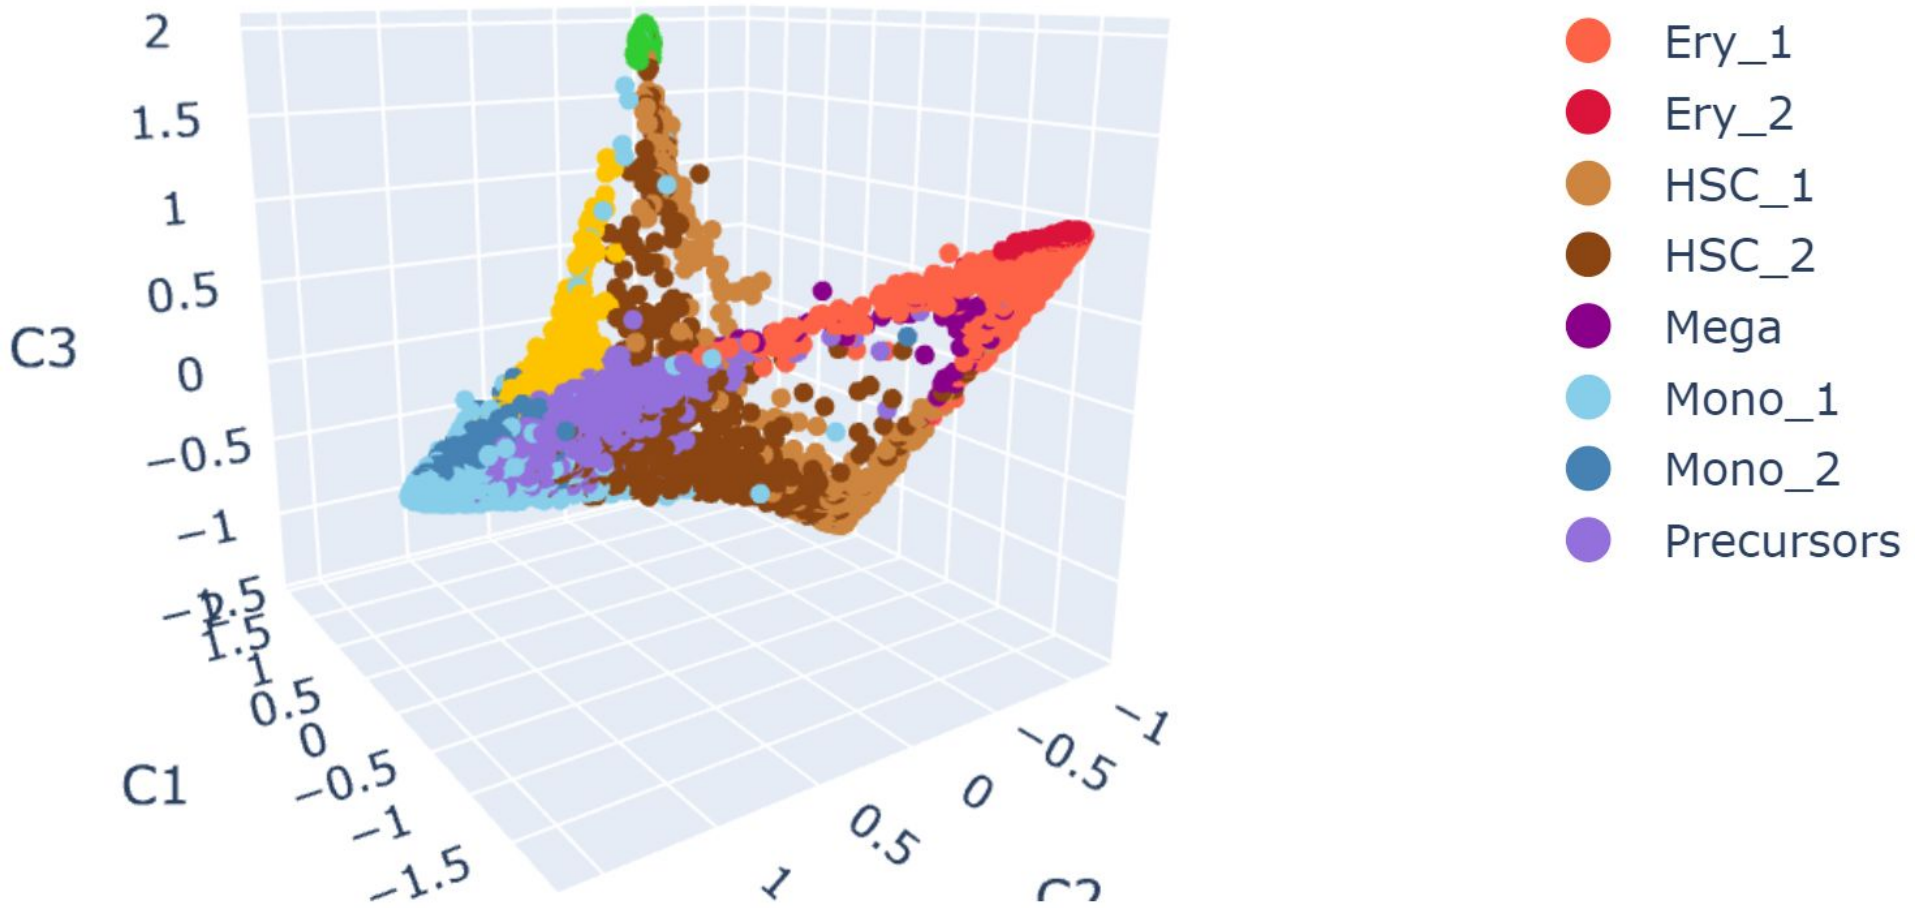
$$\sum_{t=1}^{\infty} P^t = P^1 + P^2 + \cdots + P^{\infty}$$

Pipeline: Mapas de difusión



$$\sum_{t=0}^{\infty} P^t = (I - P)^{-1}$$

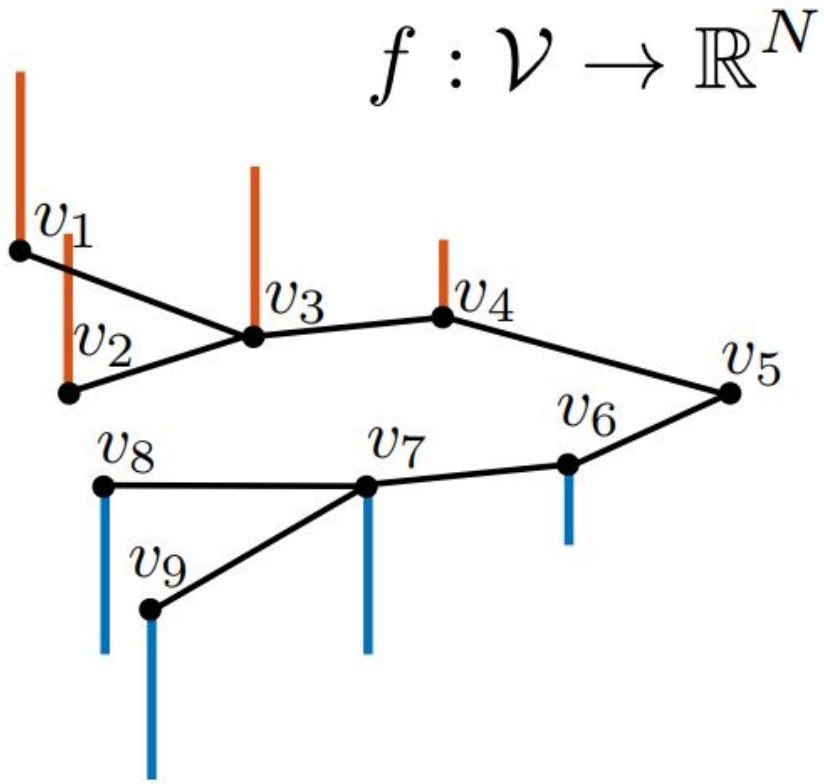
Pipeline: Mapas de difusión



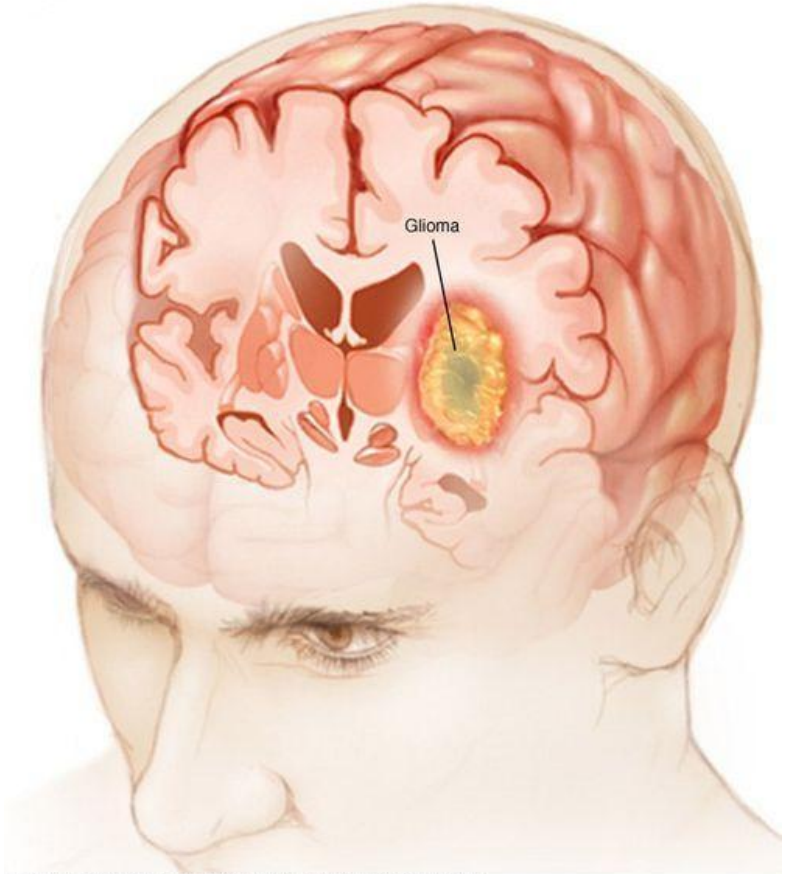
Señales: Stemness y Senescencia

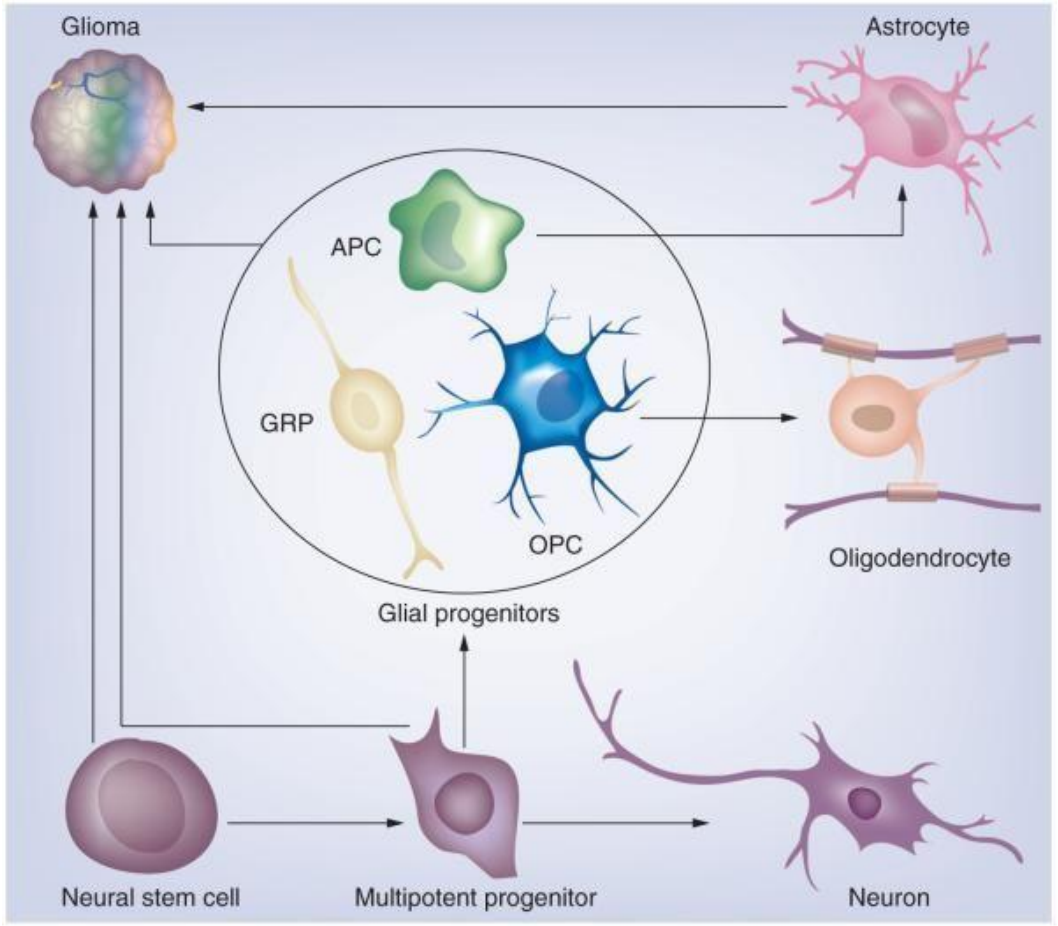
- Se puntúan células para conjuntos de genes (GSEA)

- Células con puntuaciones altas de **stemness** nos indican potencial para iniciar el proceso de divisiones



Señales: Estados tumorales

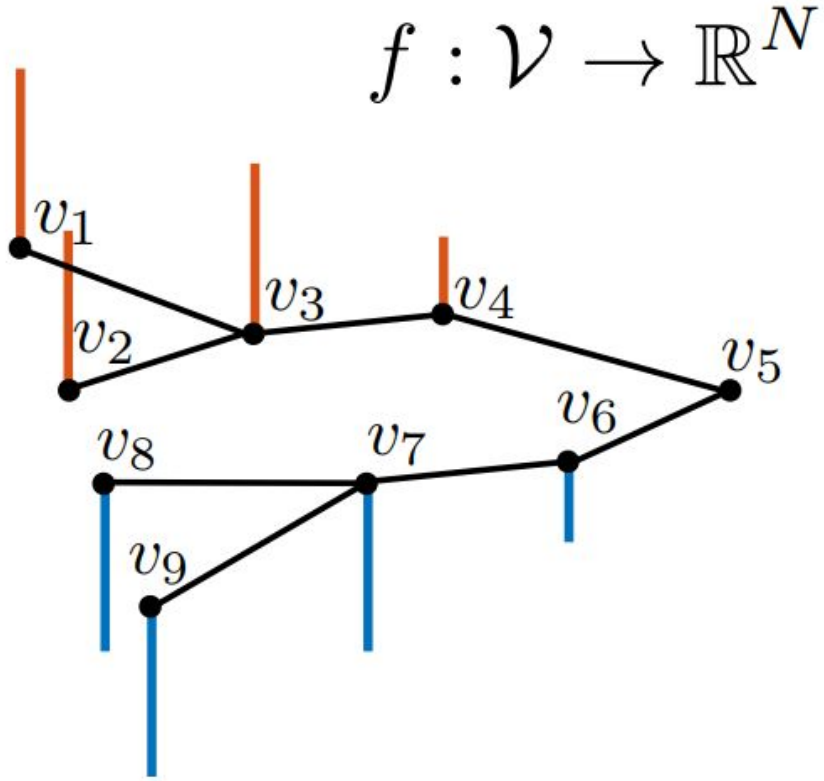


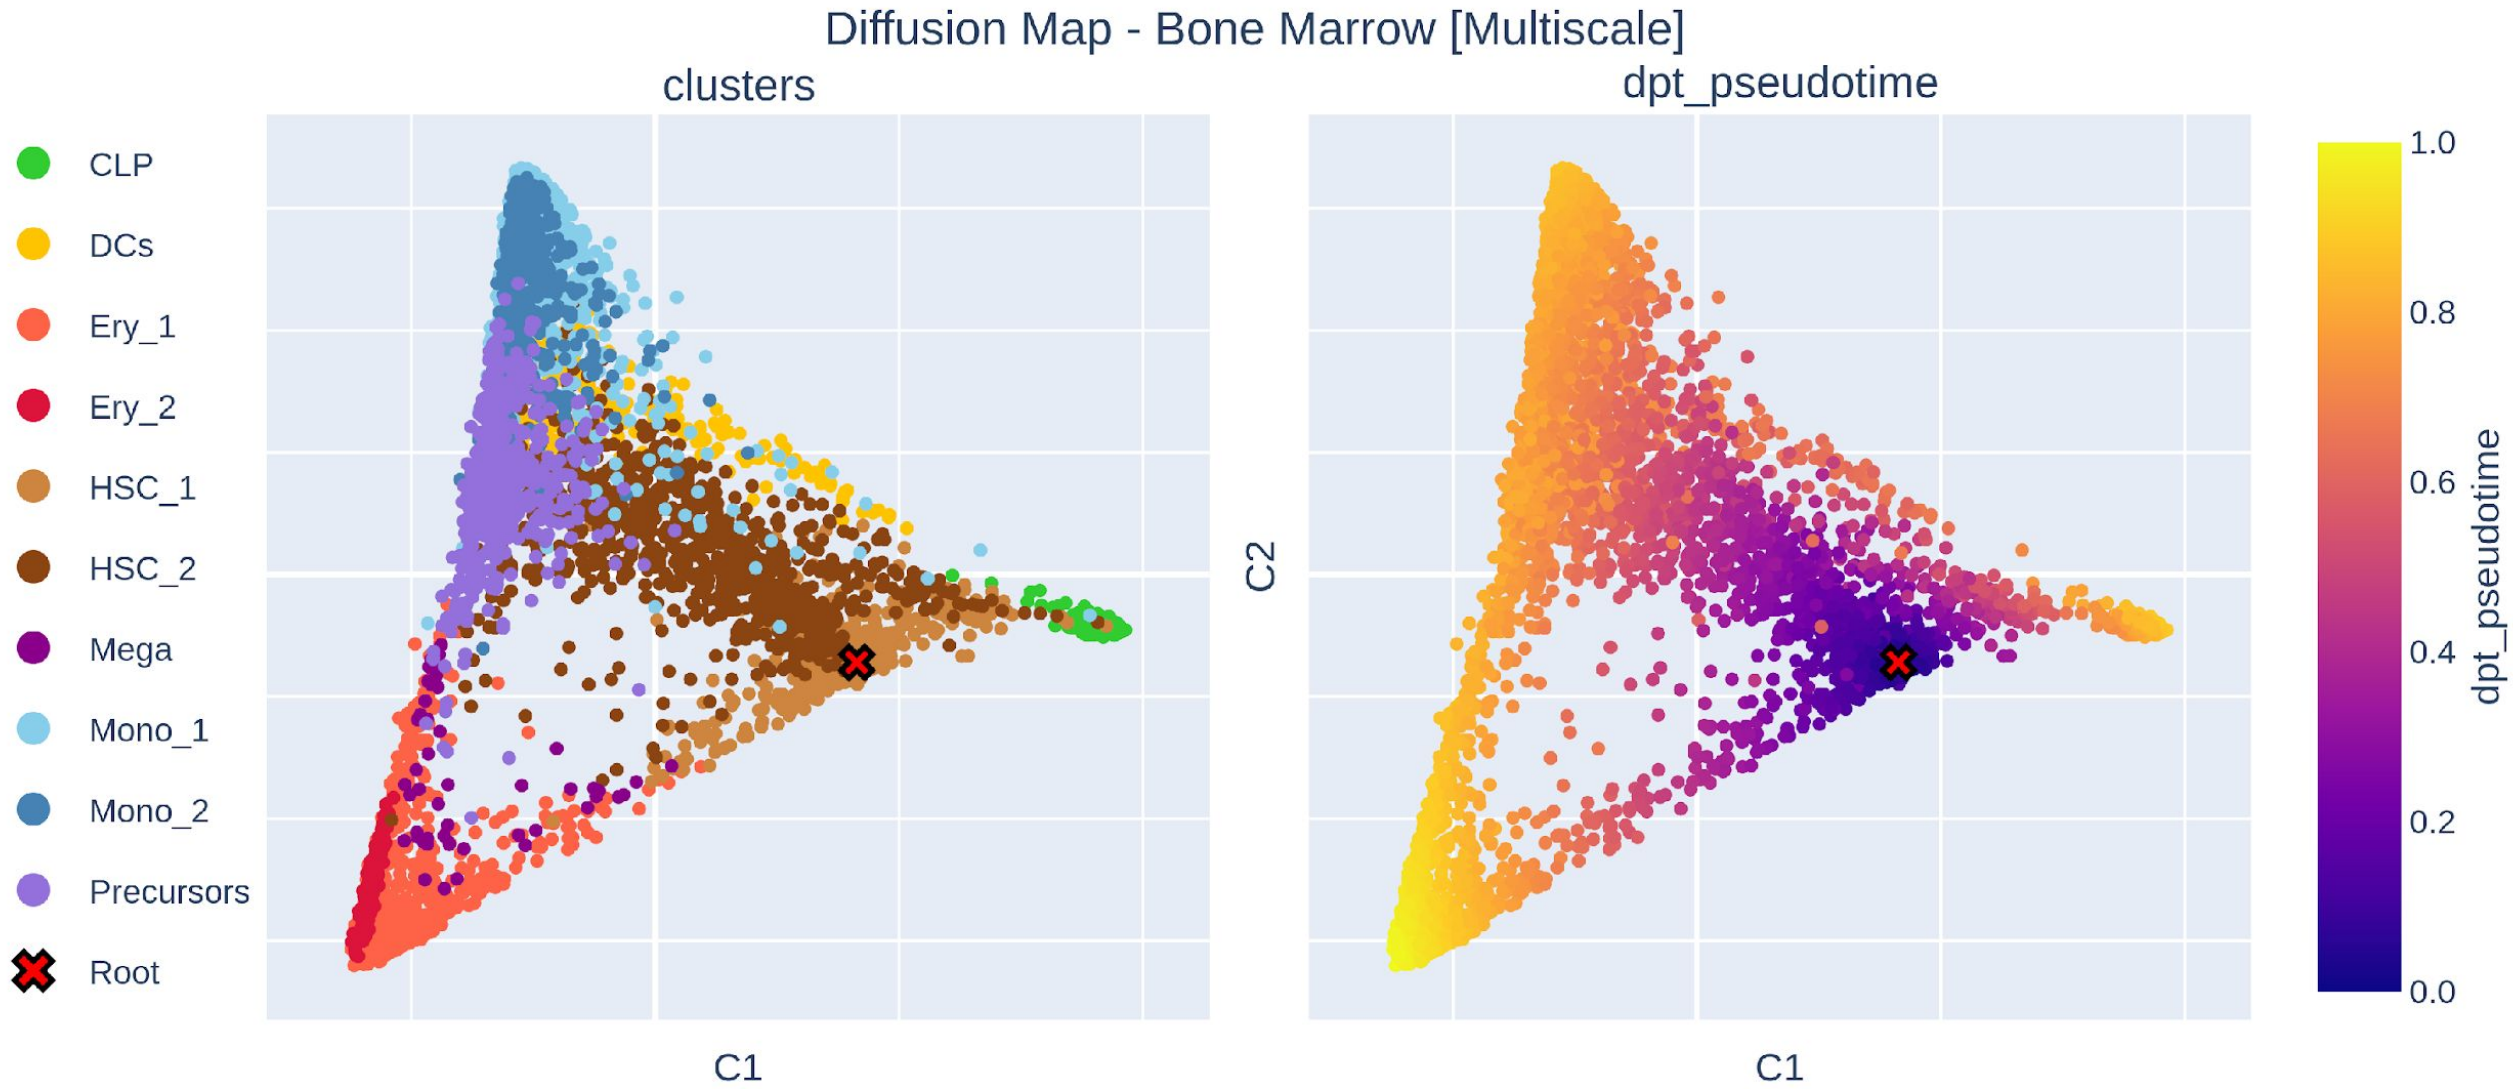


Señales: Pseudotiempo

- El pseudotiempo para una célula se calculará como distancia euclídea a una inicial

- Elegiremos como célula inicial aquella con una puntuación alta de **stemness**

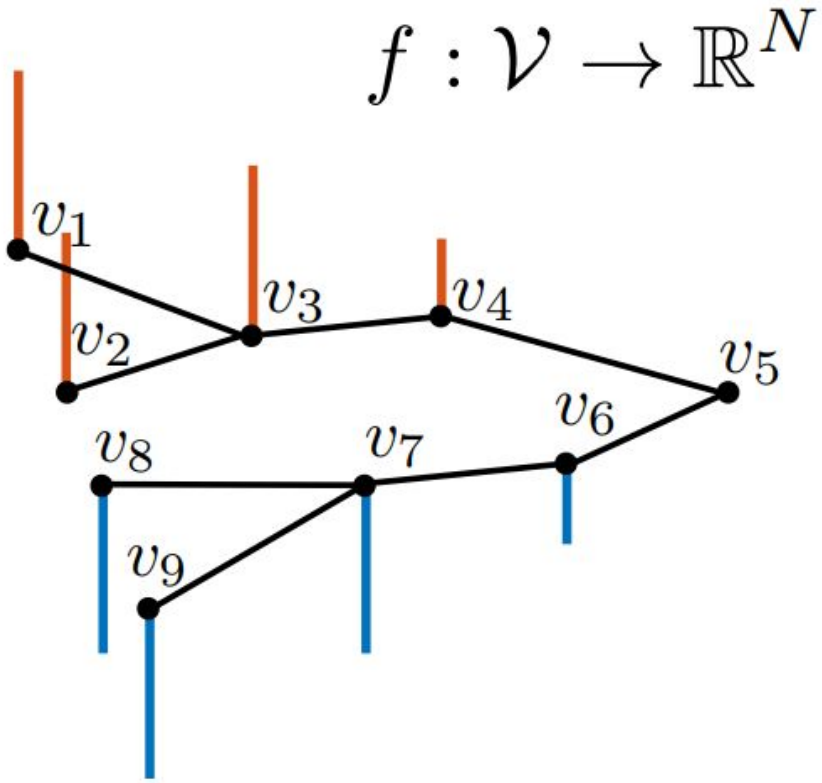



Diffusion Map - Bone Marrow [Multiscale]
clusters
dpt_pseudotime
CLP
DCs
Ery_1
Ery_2
HSC_1
HSC_2
Mega
Mono_1
Mono_2
Precursors
Root
C1
C2
C1
dpt_pseudotime
1.0
0.8
0.6
0.4
0.2
0.0

Señales: Filtros

- Se pueden utilizar los autovectores y autovalores para filtrar señales en un grafo

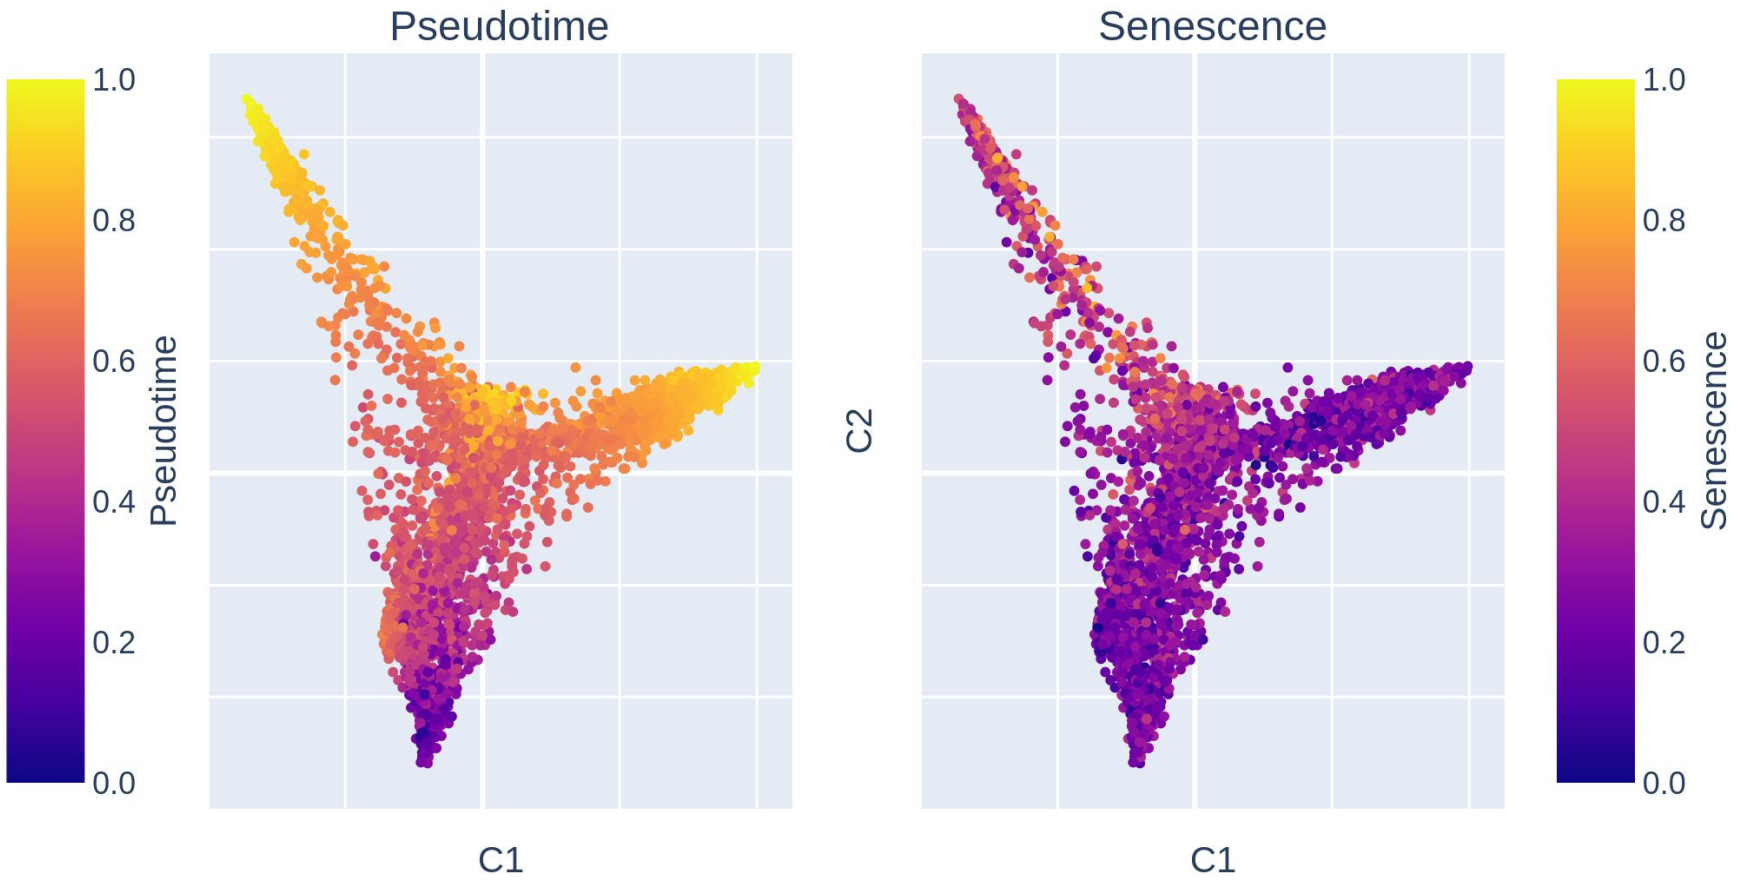
- Existe un análogo a la transformada de fourier en grafos que podría eliminar ruido



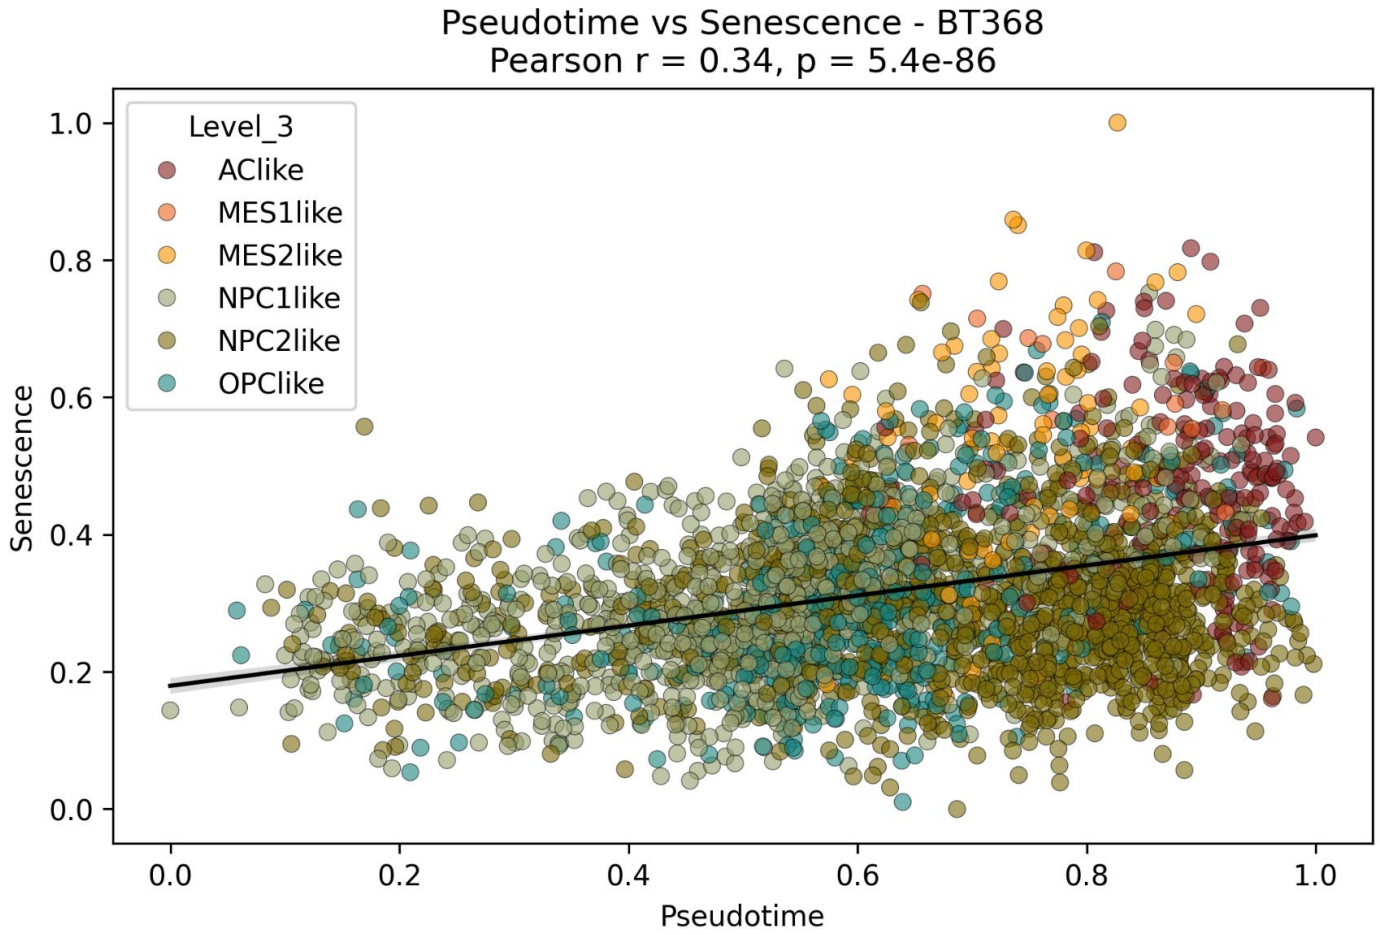
Resultados: Pacientes glioblastoma

Id	AClike	MES1like	MES2like	NPC1like	NPC2like	OPClike	Group
BT333	3.85 %	3.21 %	7.05 %	28.59 %	19.36 %	37.95 %	0
BT368	6.66 %	0.45 %	2.58 %	34.65 %	39.09 %	16.56 %	0
BT389	3.02 %	3.96 %	5.74 %	19.29 %	56.73 %	11.26 %	0
BT397	1.64 %	6.25 %	2.96 %	41.78 %	25.33 %	22.04 %	0
BT363	37.30 %	17.13 %	16.88 %	6.74 %	4.37 %	17.58 %	1
BT364	45.87 %	24.28 %	26.35 %	1.22 %	0.93 %	1.34 %	1
BT390	38.24 %	28.25 %	27.07 %	1.83 %	1.29 %	3.33 %	1
BT402	78.50 %	1.40 %	0.23 %	12.38 %	1.99 %	5.49 %	1
BT407	28.44 %	17.43 %	0.92 %	16.51 %	9.17 %	27.52 %	1
BT409	13.17 %	19.71 %	19.80 %	23.76 %	6.08 %	17.50 %	1
BT346	4.98 %	32.54 %	57.99 %	0.34 %	3.52 %	0.63 %	2

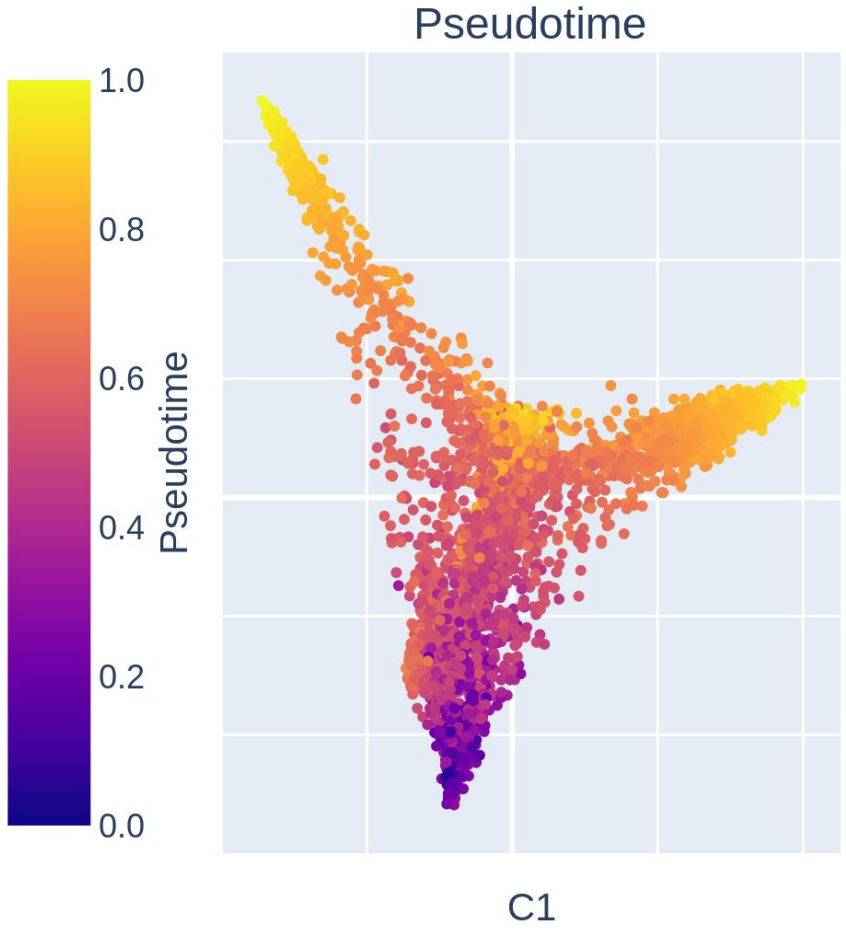
Resultados: Pacientes glioblastoma

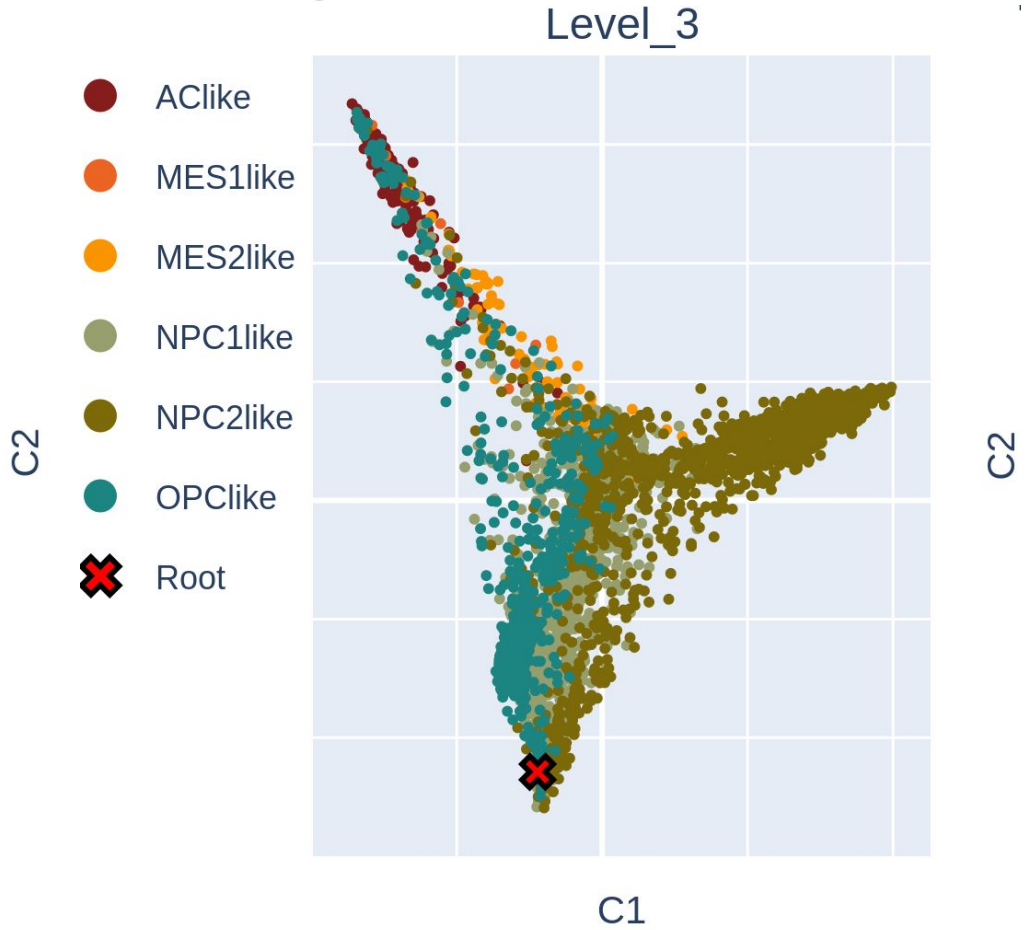


Resultados: Pacientes glioblastoma

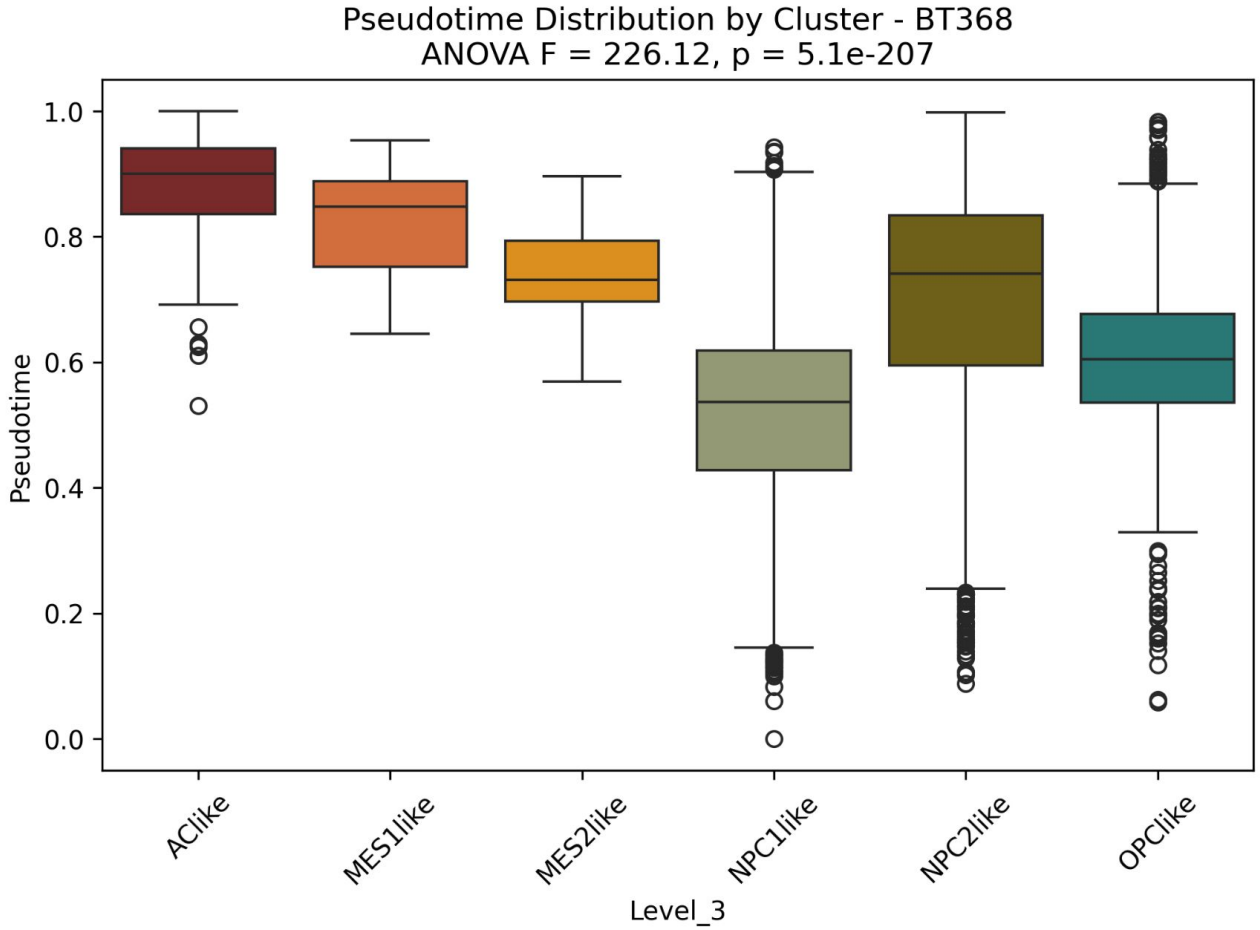


Resultados: Pacientes glioblastoma

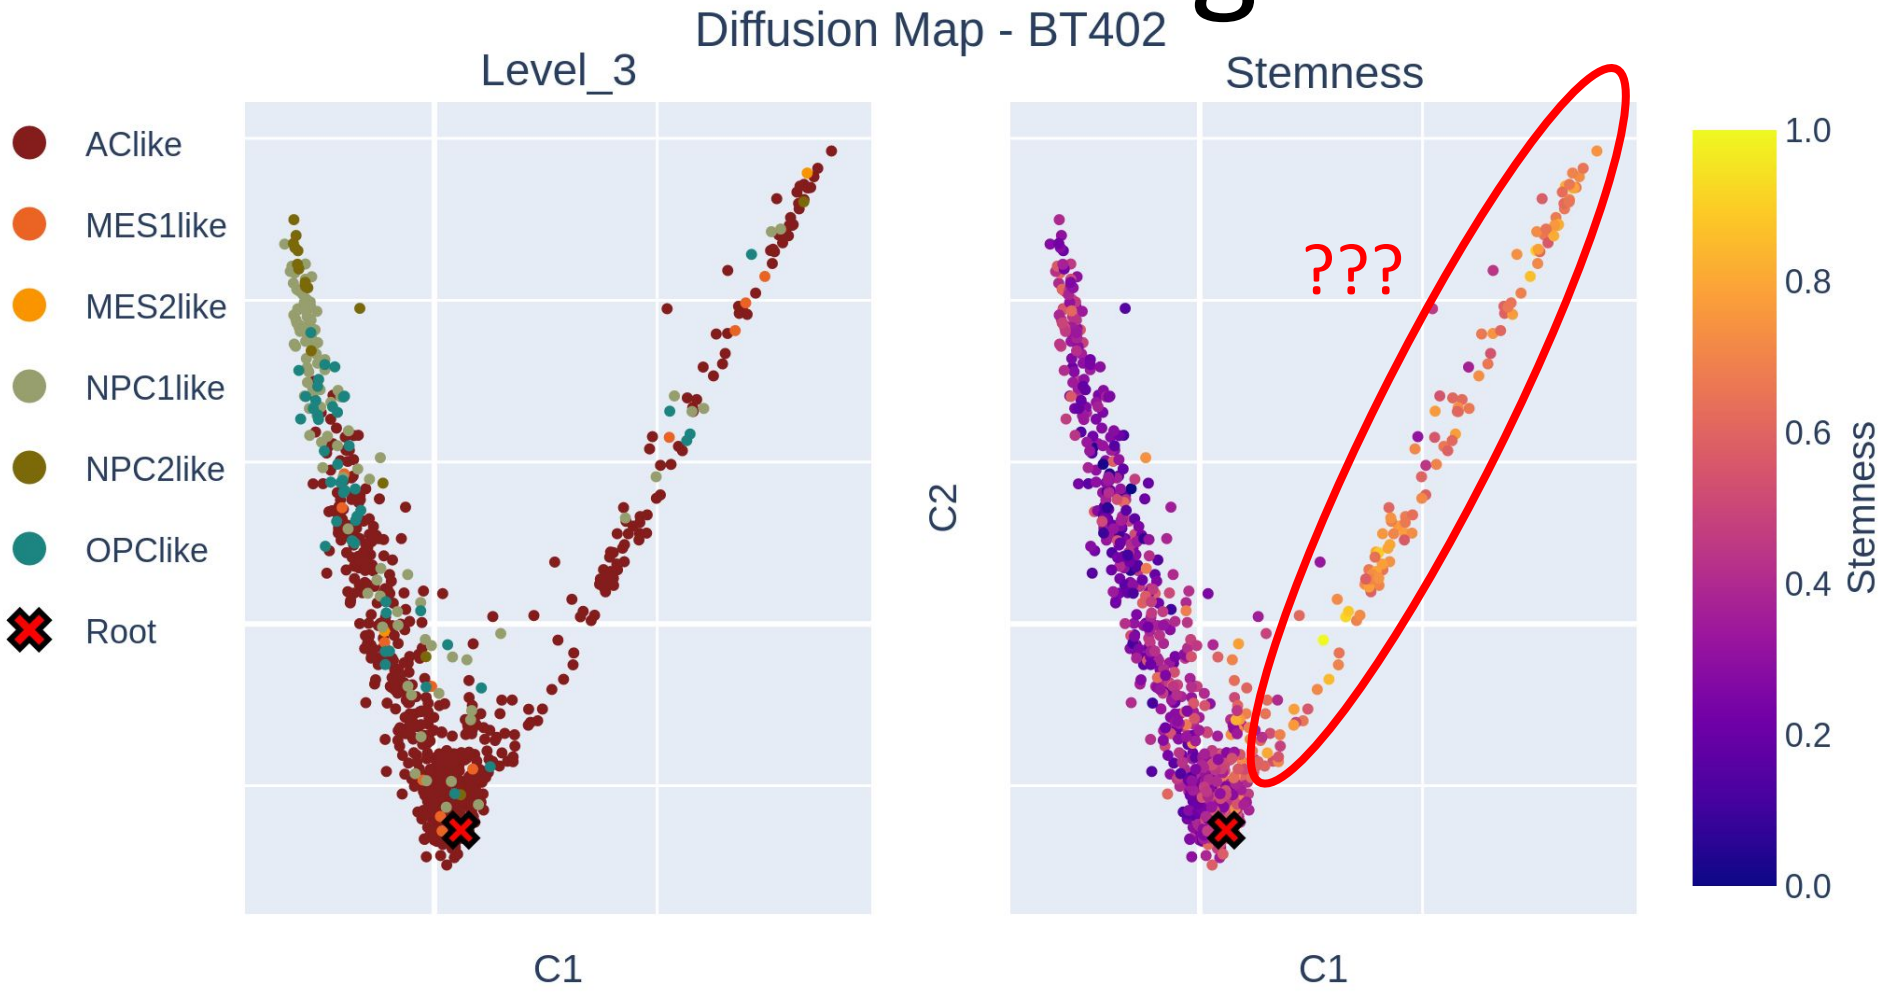


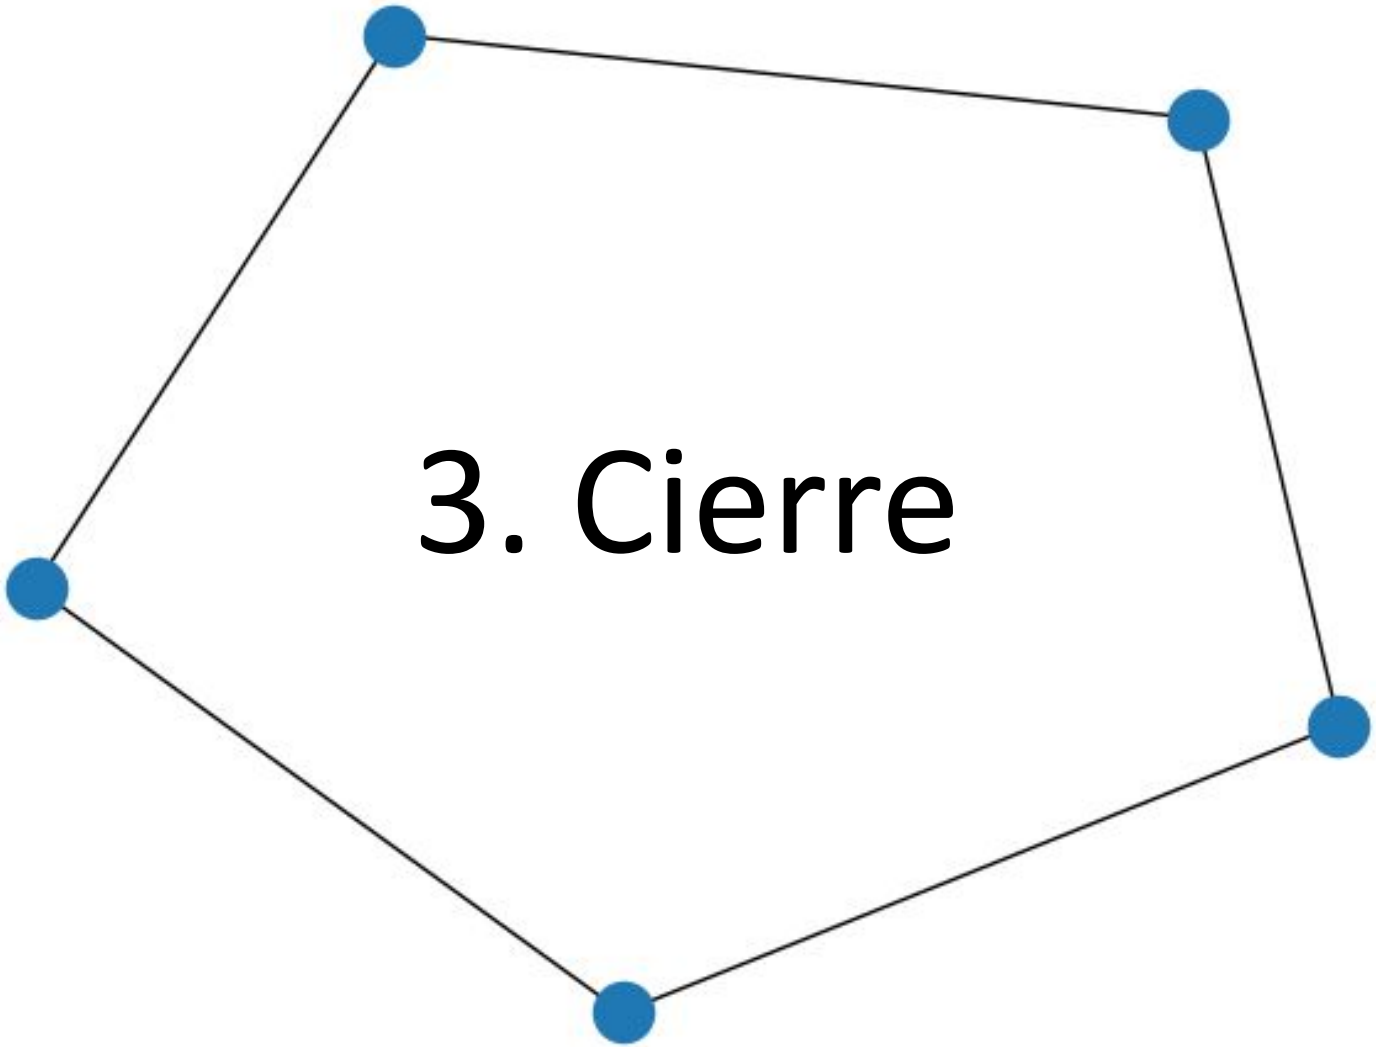


Resultados: Pacientes glioblastoma



Resultados: Pacientes glioblastoma





3. Cierre

Conclusiones

- El pseudotiempo está relacionado con la senescencia y los estados tumorales en la mayoría de casos
- Los grafos son una herramienta valiosa en el estudio de interacciones celulares
- El filtro de señales en grafos puede ser clave para un correcto análisis

Trabajo a futuro

- Basar la elección de hiperparámetros en conocimiento biológico
- Desarrollar una aplicación para investigación y uso médico
- Llevar al ámbito de experimental y clínico los resultados
- Encontrar genes relacionados con la proliferación del tumor pero de uso prescindible en células sanas


¡Gracias!